


Martin Kleinsteuber: Computer Vision


Kap. 1 – Wissenswertes über Bilder

1. Darstellung von Bildern



Darstellung von Bildern

Vom Farbbild zum Intensitätsbild



- Farbbilder bestehen aus mehreren Kanälen
- In diesem Kurs ausschließlich Graustufenbilder

Darstellung von Bildern

Kontinuierliche und diskrete Darstellung

- **Kontinuierliche** Darstellung als Funktion zweier Veränderlicher (zum Herleiten von Algorithmen)

$$I: \mathbb{R}^2 \supset \Omega \rightarrow \mathbb{R}, \quad (x, y) \mapsto I(x, y)$$

- Häufige Annahmen
 - I differenzierbar
 - Ω einfach zusammenhängend und beschränkt


- **Diskrete** Darstellung als Matrix $I \in \mathbb{R}^{m \times n}$
Eintrag $I_{k,l}$ entspricht dem Intensitätswert

- Skalierung typischerweise zwischen $[0, 255]$ oder $[0, 1]$

VGA: 480 x 640 Pixel (ca. 0.3 Megapixel)
HD: 720 x 1280 Pixel (ca. 1.0 Megapixel)
FHD: 1080 x 1920 Pixel (ca. 2.1 Megapixel)

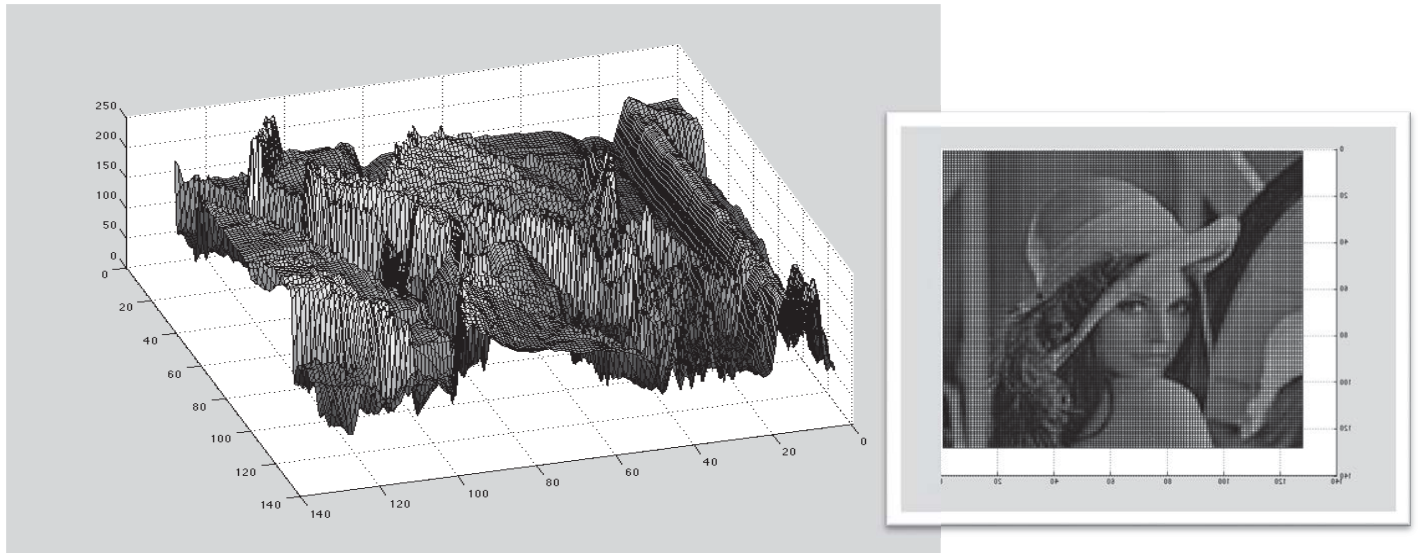
Darstellung von Bildern

Graph einer Funktion



Darstellung von Bildern

Graph eines Fotos



Darstellung von Bildern

Diskretes Abtasten

- Abtasten eines eindimensionalen Signals

$$S\{f(x)\} = (\dots, f(x-1), f(x), f(x+1), \dots)$$

- Abtasten eines Bildes

$$S\{I(x, y)\} = \begin{bmatrix} \ddots & \vdots & \vdots & \vdots & \\ \dots & I(x-1, y-1) & I(x-1, y) & I(x-1, y+1) & \dots \\ \dots & I(x, y-1) & I(x, y) & I(x, y+1) & \dots \\ \dots & I(x+1, y-1) & I(x+1, y) & I(x+1, y+1) & \dots \\ & \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Darstellung von Bildern

Diskrete Darstellung/Matrixdarstellung

- Annahme: Ursprung links oben
- Matriceintrag ist

$$I_{k,l} = S\{I(0,0)\}_{kl}$$



Columns 1 through 41

| | | | | | | | | | | | | | | | | |
|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| 163 | 163 | 162 | 161 | 160 | 160 | 159 | 159 | 159 | 165 | 169 | 173 | 176 | 170 | 148 | 126 | 103 |
| 162 | 162 | 161 | 161 | 160 | 159 | 159 | 159 | 160 | 166 | 171 | 173 | 174 | 167 | 147 | 126 | 102 |
| 161 | 161 | 160 | 160 | 159 | 159 | 159 | 158 | 162 | 168 | 173 | 173 | 171 | 163 | 145 | 126 | 101 |
| 160 | 160 | 160 | 159 | 159 | 159 | 159 | 159 | 164 | 170 | 174 | 172 | 169 | 161 | 143 | 126 | 99 |
| 160 | 160 | 160 | 160 | 160 | 160 | 160 | 160 | 167 | 171 | 172 | 169 | 167 | 160 | 143 | 125 | 99 |
| 160 | 160 | 161 | 161 | 161 | 162 | 162 | 162 | 170 | 170 | 168 | 166 | 166 | 162 | 144 | 124 | 99 |
| 161 | 161 | 162 | 162 | 163 | 164 | 164 | 165 | 172 | 169 | 163 | 162 | 167 | 164 | 145 | 123 | 100 |
| 162 | 162 | 162 | 163 | 164 | 165 | 166 | 166 | 174 | 168 | 161 | 160 | 167 | 166 | 146 | 123 | 100 |
| 158 | 160 | 162 | 164 | 167 | 170 | 171 | 170 | 164 | 167 | 164 | 160 | 164 | 166 | 147 | 121 | 97 |
| 162 | 162 | 162 | 163 | 167 | 170 | 171 | 170 | 163 | 166 | 164 | 160 | 164 | 165 | 146 | 121 | 97 |
| 166 | 163 | 162 | 165 | 168 | 169 | 168 | 168 | 161 | 165 | 164 | 160 | 163 | 164 | 145 | 120 | 97 |
| 167 | 163 | 164 | 169 | 170 | 165 | 161 | 160 | 159 | 165 | 165 | 161 | 163 | 163 | 144 | 120 | 96 |
| 166 | 164 | 167 | 173 | 170 | 157 | 150 | 151 | 158 | 165 | 167 | 163 | 164 | 163 | 144 | 120 | 94 |
| 166 | 165 | 170 | 174 | 164 | 145 | 138 | 143 | 157 | 166 | 169 | 165 | 165 | 163 | 145 | 122 | 91 |
| 169 | 167 | 171 | 171 | 154 | 132 | 129 | 140 | 158 | 168 | 172 | 168 | 167 | 164 | 146 | 123 | 89 |
| 172 | 169 | 171 | 167 | 146 | 123 | 124 | 140 | 158 | 169 | 173 | 169 | 168 | 165 | 147 | 124 | 87 |
| 175 | 173 | 171 | 156 | 124 | 101 | 115 | 143 | 163 | 172 | 173 | 167 | 165 | 161 | 143 | 120 | 86 |
| 171 | 172 | 166 | 144 | 110 | 93 | 113 | 144 | 163 | 171 | 174 | 168 | 165 | 161 | 143 | 120 | 86 |
| 169 | 167 | 155 | 126 | 94 | 86 | 113 | 144 | 162 | 171 | 174 | 168 | 166 | 162 | 142 | 119 | 87 |
| 171 | 159 | 137 | 107 | 86 | 89 | 116 | 142 | 161 | 171 | 174 | 169 | 166 | 162 | 142 | 118 | 87 |
| 170 | 146 | 116 | 95 | 88 | 97 | 120 | 140 | 161 | 171 | 174 | 170 | 167 | 162 | 142 | 117 | 88 |
| 159 | 129 | 101 | 93 | 95 | 102 | 120 | 140 | 160 | 170 | 175 | 170 | 168 | 163 | 141 | 117 | 88 |
| 139 | 111 | 93 | 97 | 98 | 97 | 116 | 144 | 159 | 170 | 175 | 171 | 169 | 163 | 141 | 116 | 89 |
| 123 | 99 | 91 | 101 | 99 | 91 | 111 | 148 | 159 | 170 | 175 | 171 | 169 | 163 | 141 | 116 | 89 |
| 96 | 99 | 97 | 99 | 101 | 97 | 111 | 141 | 157 | 167 | 171 | 167 | 166 | 162 | 143 | 119 | 90 |
| 99 | 101 | 100 | 102 | 103 | 99 | 113 | 143 | 157 | 167 | 171 | 167 | 166 | 162 | 143 | 119 | 90 |
| 101 | 103 | 102 | 103 | 105 | 100 | 114 | 144 | 157 | 167 | 171 | 167 | 166 | 162 | 143 | 119 | 89 |
| 101 | 103 | 101 | 103 | 104 | 99 | 112 | 142 | 157 | 167 | 171 | 167 | 166 | 162 | 143 | 119 | 89 |
| 99 | 102 | 99 | 100 | 101 | 96 | 109 | 139 | 157 | 167 | 171 | 167 | 166 | 162 | 143 | 119 | 88 |
| 99 | 101 | 99 | 100 | 100 | 95 | 108 | 137 | 157 | 167 | 171 | 167 | 166 | 162 | 143 | 119 | 88 |
| 102 | 104 | 101 | 101 | 102 | 96 | 109 | 138 | 157 | 167 | 171 | 167 | 166 | 162 | 143 | 119 | 87 |
| 104 | 106 | 103 | 104 | 104 | 98 | 111 | 140 | 157 | 167 | 171 | 167 | 166 | 162 | 143 | 119 | 87 |
| 103 | 108 | 105 | 103 | 106 | 105 | 115 | 137 | 156 | 166 | 171 | 170 | 172 | 168 | 145 | 118 | 87 |
| 104 | 109 | 106 | 104 | 107 | 106 | 115 | 138 | 157 | 166 | 172 | 171 | 172 | 168 | 145 | 118 | 87 |
| 105 | 110 | 107 | 105 | 108 | 107 | 117 | 139 | 157 | 167 | 172 | 171 | 173 | 169 | 146 | 119 | 88 |
| 106 | 111 | 107 | 106 | 109 | 107 | 117 | 140 | 158 | 168 | 173 | 172 | 174 | 170 | 147 | 120 | 88 |
| 106 | 111 | 107 | 106 | 109 | 107 | 117 | 140 | 159 | 169 | 174 | 174 | 175 | 171 | 148 | 121 | 89 |
| 105 | 110 | 107 | 105 | 108 | 107 | 117 | 139 | 160 | 170 | 175 | 175 | 176 | 172 | 149 | 122 | 90 |
| 104 | 109 | 106 | 104 | 107 | 106 | 115 | 138 | 161 | 171 | 176 | 175 | 177 | 173 | 150 | 123 | 91 |
| 103 | 108 | 105 | 103 | 106 | 105 | 115 | 137 | 162 | 172 | 177 | 176 | 177 | 173 | 150 | 123 | 91 |
| 103 | 108 | 104 | 103 | 107 | 107 | 119 | 143 | 162 | 171 | 175 | 173 | 175 | 172 | 150 | 124 | 92 |
| 104 | 108 | 105 | 103 | 107 | 108 | 120 | 143 | 162 | 171 | 175 | 173 | 175 | 172 | 150 | 124 | 91 |
| 104 | 109 | 105 | 104 | 108 | 109 | 120 | 144 | 162 | 171 | 176 | 174 | 175 | 172 | 150 | 124 | 91 |
| 105 | 110 | 106 | 105 | 109 | 110 | 121 | 145 | 163 | 172 | 176 | 174 | 176 | 173 | 151 | 125 | 90 |
| 106 | 111 | 108 | 106 | 110 | 111 | 122 | 146 | 164 | 173 | 177 | 175 | 176 | 173 | 152 | 125 | 89 |
| 107 | 112 | 109 | 107 | 111 | 112 | 123 | 147 | 164 | 173 | 177 | 175 | 177 | 174 | 152 | 126 | 88 |
| 108 | 113 | 109 | 108 | 112 | 112 | 124 | 148 | 164 | 173 | 178 | 176 | 177 | 174 | 152 | 126 | 88 |
| 109 | 113 | 110 | 108 | 112 | 113 | 125 | 148 | 165 | 174 | 178 | 176 | 178 | 175 | 153 | 126 | 87 |
| 117 | 114 | 107 | 110 | 115 | 111 | 120 | 144 | 159 | 170 | 177 | 175 | 176 | 173 | 153 | 129 | 91 |
| 118 | 115 | 108 | 110 | 114 | 109 | 118 | 143 | 159 | 170 | 177 | 175 | 176 | 173 | 153 | 129 | 91 |
| 119 | 116 | 109 | 110 | 112 | 107 | 115 | 140 | 159 | 170 | 177 | 175 | 176 | 173 | 153 | 129 | 89 |
| 119 | 117 | 111 | 110 | 111 | 103 | 112 | 138 | 159 | 170 | 177 | 175 | 176 | 173 | 153 | 129 | 89 |
| 118 | 117 | 111 | 109 | 109 | 101 | 110 | 137 | 159 | 170 | 177 | 175 | 176 | 173 | 153 | 129 | 89 |
| 116 | 116 | 111 | 109 | 107 | 99 | 109 | 137 | 159 | 170 | 177 | 175 | 176 | 173 | 153 | 129 | 89 |
| 113 | 114 | 110 | 108 | 106 | 98 | 109 | 138 | 159 | 170 | 177 | 175 | 176 | 173 | 153 | 129 | 91 |


Zusammenfassung

- Bilder in Grautönen
- Bilder als Matrizen
- Bilder als glatte Funktionen



Martin Kleinsteuber: Computer Vision

Kap. 1 – Wissenswertes über Bilder

2. Bildgradient



Der Gradient eines Bildes



Kanten sind starke lokale
Änderungen der Intensität

Lokale Änderungen
werden durch den
Gradienten beschrieben

$$\nabla I(x, y) = \begin{bmatrix} \frac{d}{dx} I(x, y) \\ \frac{d}{dy} I(x, y) \end{bmatrix}$$

Video

Gradient eines Bildes

Wie schätzt man den Gradienten?

- Gegeben ist das Bild in diskreter Form $I \in \mathbb{R}^{m \times n}$
- Naiver Ansatz:

$$\frac{d}{dx} I(x, y) \approx I(x+1, y) - I(x, y)$$
$$\frac{d}{dy} I(x, y) \approx I(x, y+1) - I(x, y)$$

Video

Diskretes und kontinuierliches Signal Interpolation

- Vom diskreten Signal $f[x] = S\{f(x)\}$ zum kontinuierlichen Signal $f(x)$

- Interpoliertes Signal ist Faltung der Abtastwerte mit dem Interpolationsfilter



$$f(x) \approx \sum_{k=-\infty}^{\infty} f[k] h(x-k) =: f[x] * h(x)$$

Video

Diskretes und kontinuierliches Signal

Interpolationsfilter

- Diskretes Signal: $f[x] = S\{f(x)\}$
- Kontinuierliches Signal: $f(x) \approx f[x] * h(x)$
- Gaußfilter: $h(x) = g(x)$
- Ideales Interpolationsfilter: $h(x) = \text{sinc}(x)$
- Damit gilt: $f[x] * h(x) = f(x)$



Die diskrete Ableitung

Mit Hilfe des rekonstruierten Signals

- Algorithmisch
 1. Rekonstruktion des kontinuierlichen Signals
 2. Ableitung des kontinuierlichen Signals
 3. Abtastung der Ableitung

■ Herleitung:

$$f'(x) \approx \frac{d}{dx}(f[x] * h(x))$$


$$= f[x] * h'(x)$$

$$f'[x] = f[x] * h'[x]$$

$$= \sum_{k=-\infty}^{\infty} f[x-k] h'[k]$$


■ Sinc-Funktion

- Langsames Abklingen



■ Gaußfilter

- Schnelles Abklingen





Zweidimensionale Rekonstruktion

Separables 2D-Gaußfilter

■ 2D-Rekonstruktion: $I(x, y) \approx I[x, y] * h(x, y) = \sum_{k=-\infty}^{\infty} \sum_{l=-\infty}^{\infty} I[k, l] g(x - k) g(y - l)$

$$h(x, y) := g(x)g(y)$$



Video



Zweidimensionale Ableitung

Ausnutzen der Separabilität

■ Ableitung in x-Richtung

$$\begin{aligned} \frac{d}{dx} I(x, y) &\approx I[x, y] * \left(\frac{d}{dx} h(x, y) \right) \\ &= \sum_{k=-\infty}^{\infty} \sum_{l=-\infty}^{\infty} I[k, l] g'(x - k) g(y - l) \end{aligned}$$

$$\begin{aligned} S\left\{ \frac{d}{dx} I(x, y) \right\} &= I[x, y] * g'[x] * g[y] \\ &= \sum_{k=-\infty}^{\infty} \sum_{l=-\infty}^{\infty} I[x - k, y - l] g'[k] g[l] \end{aligned}$$



Video

Endliche Approximation des Gaußfilters

Normierung des endlichen Filters

- In der Praxis wird die unendliche Summe durch wenige Summanden approximiert

- Wie wählt man eine geeignete Gewichtung C des Gaußfilters $g(x) = Ce^{\frac{-x^2}{2\sigma^2}}$?

- Interpoliertes Signal: $f(x) \approx \sum_{k=-\infty}^{\infty} f[k]g(x-k)$

- Abgetastetes interpoliertes Signal: $f[x] \approx \sum_{k=-\infty}^{\infty} f[x-k]g[k]$

- Approximation durch endliche Summe:

$$f[x] \approx \sum_{k=-n}^n f[x-k]g[k]$$

Video

Endliche Approximation des Gaußfilters

Normierung des endlichen Filters

- Die endliche Approximation von $f[x]$ ist eine gewichtete Summe der Werte $f[x-n], \dots, f[x+n]$ mit den Gewichten $g[n], \dots, g[-n]$

- Normierungskonstante C so gewählt, dass sich alle Gewichte zu 1 addieren

- Wähle $C = \frac{1}{\sum_{-n \leq k \leq n} e^{\frac{-k^2}{2\sigma^2}}}$

Video

Sobel-Filter

Herleitung

- Approximation von $S\{\frac{d}{dx}I(x,y)\} = I[x,y] * g'[x] * g[y] = \sum_{k=-\infty}^{\infty} \sum_{l=-\infty}^{\infty} I[x-k, y-l] g'[k] g[l]$

durch endliche Summe $\sum_{k=-1,0,1} \sum_{l=-1,0,1} I[x-k, y-l] g'[k] g[l]$

- Daraus folgt der Normierungsfaktor $C = \frac{1}{1 + 2e^{-\frac{1}{2\sigma^2}}}$
- Für die Wahl $\sigma = \sqrt{\frac{1}{2 \log 2}}$ ergeben sich somit die Werte

$$g[-1] = \frac{1}{4}; g[0] = \frac{1}{2}; g[1] = \frac{1}{4}$$

$$g'[-1] = \frac{1}{2} \log 2; g'[0] = 0; g'[1] = -\frac{1}{2} \log 2 \quad (\frac{1}{2} \log 2 \approx 0.35)$$

Video

Sobel-Filter

Herleitung

- Aus praktischen Gründen sind ganzzahlige Filterkoeffizienten erwünscht
- Für das Detektieren von Intensitätsunterschieden ist ein Vielfaches des Gradienten ausreichend

$$\frac{1}{8} \log 2 \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix}$$


Ganzzahlige Approximation

| | | |
|---|---|----|
| 1 | 0 | -1 |
| 2 | 0 | -2 |
| 1 | 0 | -1 |


Horizontales Sobel-Filter

Beispiel

Sobel-Filterung



| | | |
|----|----|----|
| 1 | 2 | 1 |
| 0 | 0 | 0 |
| -1 | -2 | -1 |



| | | |
|---|---|----|
| 1 | 0 | -1 |
| 2 | 0 | -2 |
| 1 | 0 | -1 |

Zusammenfassung


Bildgradient

- Der Bildgradient ist ein wichtiges Werkzeug für die Bestimmung von lokalen Intensitätsänderungen
- Diskrete Ableitung wird durch Differenzieren des interpolierten Signals berechnet
- Sobel-Filter sind ganzzahlige Approximation eines Vielfachen des Gradienten

Martin Kleinsteuber: Computer Vision

Kap. 1 – Wissenswertes über Bilder

3. Merkmalspunkte – Ecken und Kanten



Ecken und Kanten...


...liefern markante Bildmerkmale

- Bestimmung von Konturen
- Berechnungen von Bewegungen in Bildsequenzen
- Schätzen von Kamerabewegung
- Registrierung von Bildern
- 3D-Rekonstruktion



Harris Ecken- und Kantendetektor

Änderung des Bildsegments in Abhängigkeit der Verschiebung



- Ecke: Verschiebung in jede Richtung bewirkt Änderung
- Kante: Verschiebung in jede bis auf genau eine Richtung bewirkt Änderung
- Homogene Fläche: Keine Änderung, egal in welche Richtung

Harris Ecken- und Kantendetektor

Formelle Beschreibung der Änderung

- Position im Bild: $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$, $I(x) = I(x_1, x_2)$
- Verschiebungsrichtung: $u = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}$
- Änderung des Bildsegments:

$$S(u) = \int_W \left(I(x+u) - I(x) \right)^2 dx$$

- Differenzierbarkeit von I :

$$\lim_{u \rightarrow 0} \frac{I(x+u) - I(x) - \nabla I(x)^\top u}{\|u\|} = 0$$

Harris Ecken- und Kantendetektor

Approximation der Änderung

- Folgerung aus Differenzierbarkeit: $I(x + u) - I(x) = \nabla I(x)^\top u + o(\|u\|)$
- Restterm $o(\|u\|)$ mit der Eigenschaft $\lim_{u \rightarrow 0} o(\|u\|)/\|u\| = 0$
- Approximation für kleine Verschiebungen: $I(x + u) - I(x) \approx \nabla I(x)^\top u$
- Approximation der Änderung im Bildsegment:

$$S(u) = \int_W \left(I(x + u) - I(x) \right)^2 dx \approx \int_W \left(\nabla I(x)^\top u \right)^2 dx$$

Harris Ecken- und Kantendetektor

Die Harris-Matrix

- Ausmultiplizieren des Integrals:

$$\int_W \left(\nabla I(x)^\top u \right)^2 dx = u^\top \left(\int_W \nabla I(x) \nabla I(x)^\top dx \right) u$$

- Harris-Matrix: $G(x) = \int_W \nabla I(x) \nabla I(x)^\top dx$

$$\nabla I(x) \nabla I(x)^\top = \begin{bmatrix} \left(\frac{\partial}{\partial x_1} I(x) \right)^2 & \frac{\partial}{\partial x_1} I(x) \frac{\partial}{\partial x_2} I(x) \\ \frac{\partial}{\partial x_2} I(x) \frac{\partial}{\partial x_1} I(x) & \left(\frac{\partial}{\partial x_2} I(x) \right)^2 \end{bmatrix}$$

- Approximative Änderung des Bildsegments:

$$S(u) \approx u^\top G(x) u$$

Exkurs: Lineare Algebra

Positiv definite und positiv semidefinite Matrizen

■ **Definition.** Eine reelle symmetrische Matrix $A = A^\top$ heißt

- positiv definit, falls $x^\top Ax > 0$, $x \neq 0$
- positiv semidefinit, falls $x^\top Ax \geq 0$

■ **Beispiele**

- Die Null-Matrix ist positiv semidefinit, aber nicht positiv definit.
- Die Einheitsmatrix ist positiv definit.
- Jede positiv definite Matrix ist auch positiv semidefinit.
- $G(x)$ ist positiv semi-definit. Warum?

Exkurs: Lineare Algebra

Positiv definite und positiv semidefinite Matrizen

■ **Satz.** Für reelle symmetrische Matrizen $A = A^\top$ ist gleichbedeutend:

- A positiv (semi-) definit
- Alle Eigenwerte von A sind größer als Null (größer oder gleich Null)

■ **Eigenwertzerlegung reeller symmetrischer Matrizen.**

Jede reelle symmetrische Matrix $A = A^\top$ kann zerlegt werden in ein Produkt $A = V\Lambda V^\top$ mit $VV^\top = I$ und einer Diagonalmatrix Λ , auf deren Diagonale die Eigenwerte von A stehen. Die Spalten von V sind die zugehörigen Eigenvektoren.

Harris Ecken- und Kantendetektor

Eigenwertzerlegung

- Eigenwertzerlegung der Harris-Matrix:

$$G(x) = \int_W \nabla I(x) \nabla I(x)^\top dx = V \begin{bmatrix} \lambda_1 & \\ & \lambda_2 \end{bmatrix} V^\top$$

mit $VV^\top = I_2$ und den Eigenwerten $\lambda_1 \geq \lambda_2 \geq 0$.

- Änderung in Abhängigkeit der Eigenvektoren: $V = [v_1, v_2]$

$$S(u) \approx u^\top G(x) u = \lambda_1 (u^\top v_1)^2 + \lambda_2 (u^\top v_2)^2$$

Harris Ecken- und Kantendetektor

Art des Merkmals in Abhängigkeit der Eigenwerte

- Beide Eigenwerte positiv $S(u) \approx u^\top G(x) u = \lambda_1 (u^\top v_1)^2 + \lambda_2 (u^\top v_2)^2$
 - $S(u) > 0$ für alle u (Änderung in jede Richtung)
 - Untersuchtes Bildsegment enthält eine Ecke
- Ein Eigenwert positiv, ein Eigenwert gleich null
 - $S(u) \begin{cases} = 0, & \text{falls } u = r v_2 \\ > 0, & \text{sonst} \end{cases}$ (Keine Änderung nur in Richtung des Eigenvektors zum Eigenwert 0)
 - Untersuchtes Bildsegment enthält eine Kante
- Beide Eigenwerte gleich null
 - $S(u) = 0$ für alle u (Keine Änderung, egal in welche Richtung)
 - Untersuchtes Bildsegment ist eine homogene Fläche

Praktische Realisierung des Harris-Detektors

Berechnung der Harris-Matrix


- Approximiere $G(x)$ durch endliche Summe

$$G(x) = \int_W \nabla I(x) \nabla I(x)^\top dx \approx \sum_{\tilde{x} \in W(x)} \nabla I(\tilde{x}) \nabla I(\tilde{x})^\top$$

- Gewichtete Summe in Abhängigkeit der Position von \tilde{x}

$$G(x) \approx \sum_{\tilde{x} \in W(x)} w(\tilde{x}) \nabla I(\tilde{x}) \nabla I(\tilde{x})^\top$$

- Gewichte $w(\tilde{x}) > 0$ betonen Einfluss der zentralen Pixel



Praktische Realisierung des Harris-Detektors

Eigenwerte

- In der Realität nehmen Eigenwerte nie genau den Wert Null an, z.B. auf Grund von Rauschen, diskreter Abtastung und numerischen Ungenauigkeiten
- Charakteristik in der Praxis
 - Ecke: zwei große Eigenwerte
 - Kante: ein großer Eigenwert, ein kleiner Eigenwert
 - Homogene Fläche: zwei kleine Eigenwerte
- Entscheidung mittels empirischer Schwellwerte

Exkurs: Lineare Algebra

Eigenwerte, Determinante, Spur

- Zusammenhang von Eigenwerten, Determinante und Spur einer Matrix.

Seien $\lambda_1, \dots, \lambda_n$ Eigenwerte einer Matrix G .

Dann gilt

- $\det G = \prod_{i=1}^n \lambda_i$ (Determinante ist das Produkt der Eigenwerte)
- $\text{tr } G = \sum_{i=1}^n \lambda_i$ (Spur ist die Summe der Eigenwerte)


Praktische Realisierung des Harris-Detektors

Ein einfaches Kriterium für Ecken und Kanten

- Betrachte die Größe $H := \det(G) - k(\text{tr}(G))^2$

$$H = (1 - 2k)\lambda_1\lambda_2 - k(\lambda_1^2 + \lambda_2^2)$$

- Ecke (beide Eigenwerte groß)
 - H größer als ein positiver Schwellwert
- Kante (ein Eigenwert groß, ein Eigenwert klein)
 - H kleiner als ein negativer Schwellwert
- Homogene Fläche (beide Eigenwerte klein)
 - H betragsmäßig klein



Zusammenfassung

Harris-Detektor zur Bestimmung von Merkmalspunkten

- Auswertung der (approximierten) Harris-Matrix

$$G(x) \approx \sum_{\tilde{x} \in W(x)} w(\tilde{x}) \nabla I(\tilde{x}) \nabla I(\tilde{x})^\top$$

- Eigenwertzerlegung von $G(x)$ liefert auch Info über Richtung etwaiger Kanten
- Effiziente Implementierung mit Hilfe des Ausdrucks


$$H := \det(G) - k(\text{tr}(G))^2$$

- Entscheidung mittels Schwellwerten
 - Ecke: $0 < \tau_+ < H$
 - Kante: $H < \tau_- < 0$
 - Homogene Fläche: $\tau_- < H < \tau_+$

Martin Kleinsteuber: Computer Vision

Kap. 1 – Wissenswertes über Bilder

4. Korrespondenzschätzung für Merkmalspunkte



Korrespondenzschätzung

Problemstellung

- Gegeben sind zwei Bilder $I_1: \Omega_1 \rightarrow \mathbb{R}$, $I_2: \Omega_2 \rightarrow \mathbb{R}$ derselben 3D-Szene
- Finde Paare von Bildpunkten $(x^{(i)}, y^{(i)}) \in \Omega_1 \times \Omega_2$, die zu gleichen 3D-Punkten korrespondieren.



Korrespondenzschätzung

Problemstellung

- In dieser Session: Korrespondenzen für Merkmalspunkte in I_1 und I_2
- Habe Merkmalspunkte $\{x_1, \dots, x_n\} \subset \Omega_1$ und $\{y_1, \dots, y_n\} \subset \Omega_2$
- Finde passende Paare von Merkmalspunkten


Naive Lösung des Problems

Sum of squared differences (SSD)

- Betrachte Bildausschnitte V_i um x_i und W_i um y_i in Matrixdarstellung und vergleiche die Intensitäten



$d(\quad , \quad)$



Sum of Squared Differences (SSD)

Formelle Beschreibung

- Ein Kriterium: $d(V, W) = \|V - W\|_F^2$
- Dabei ist $\|A\|_F^2 = \sum_{kl} A_{kl}^2$ die quadrierte Frobeniusnorm
- Finde zu V_i das W_j mit $j = \arg \min_{k=1, \dots, n} d(V_i, W_k)$
- Annahme: Wenn W_j zu V_i passt, dann auch umgekehrt

Schwachpunkte der SSD-Methode


Änderungen der Beleuchtung oder Drehungen




- Normierung von Intensität und Orientierung benötigt!

Rotationsnormierung

mittels Gradientenrichtung






Rotationsnormierung mittels Gradientenrichtung



Rotationsnormierung mittels Gradientenrichtung

■ Vorverarbeitung:

1. Bestimme Gradienten in allen Merkmalspunkten
2. Rotiere Regionen um Merkmalspunkte so, dass Gradient in eine Richtung zeigt.
3. Extrahiere V , W aus rotierten Regionen



Bias-and-Gain-Modell

Modellierung von Kontrast und Helligkeit

- Skalierung der Intensitätswerte (Gain)
mit α
- Verschiebung der Intensitätswerte (Bias)
mit β
- Gain-Modell: $W \approx \alpha V$
- Bias-Modell: $W \approx V + \beta \mathbf{1}\mathbf{1}^\top$
 $\mathbf{1} = (1, \dots, 1)^\top$
- Bias-and-Gain Modell: $W \approx \alpha V + \beta \mathbf{1}\mathbf{1}^\top$



Skalierung bewirkt
Kontraständerung



Verschiebung bewirkt
Helligkeitsänderung

Bias-and-Gain-Modell

Berechnung des Mittelwerts

- Mittelwertbildung der Intensität

$$\begin{aligned}
 \bar{W} &= \frac{1}{N} (\mathbf{1}\mathbf{1}^\top W \mathbf{1}\mathbf{1}^\top) \\
 &\approx \frac{1}{N} (\mathbf{1}\mathbf{1}^\top (\alpha V + \beta \mathbf{1}\mathbf{1}^\top) \mathbf{1}\mathbf{1}^\top) \\
 &= \alpha \frac{1}{N} (\mathbf{1}\mathbf{1}^\top V \mathbf{1}\mathbf{1}^\top) + \beta \mathbf{1}\mathbf{1}^\top \\
 &= \alpha \bar{V} + \beta \mathbf{1}\mathbf{1}^\top
 \end{aligned}$$

- Subtraktion der Mittelwertmatrix

$$\begin{aligned}
 W - \bar{W} &\approx \alpha V + \beta \mathbf{1}\mathbf{1}^\top - (\alpha \bar{V} + \beta \mathbf{1}\mathbf{1}^\top) \\
 &= \alpha (V - \bar{V})
 \end{aligned}$$

Bias-and-Gain-Modell

Berechnung der Standardabweichung

- Standardabweichung der Intensität

$$\begin{aligned}\sigma(W) &= \sqrt{\frac{1}{N-1} \|W - \bar{W}\|_F^2} \\ &= \sqrt{\frac{1}{N-1} \operatorname{tr} \left((W - \bar{W})^\top (W - \bar{W}) \right)} \\ &\approx \sqrt{\frac{1}{N-1} \operatorname{tr} \left(\alpha (V - \bar{V})^\top \alpha (V - \bar{V}) \right)} \\ &= \alpha \sigma(V)\end{aligned}$$

Bias-and-Gain-Modell

Kompensation von Bias und Gain

- Normalisierung der Bildsegmente durch
 - Subtraktion des Mittelwertes
 - Division durch Standardabweichung

$$\begin{aligned}W_n &:= \frac{1}{\sigma(W)} (W - \bar{W}) \\ &\approx \frac{1}{\alpha \sigma(V)} (\alpha (V - \bar{V})) \\ &= \frac{1}{\sigma(V)} (V - \bar{V}) \\ &=: V_n\end{aligned}$$

Normalized Cross Correlation (NCC)

Herleitung aus SSD

- SSD von zwei normalisierten Bildsegmenten
$$\|V_n - W_n\|_F^2 = 2(N - 1) - 2\text{tr}(W_n^\top V_n)$$
- Die Normalized Cross Correlation der beiden Bildsegmente ist definiert als $\frac{1}{N-1}\text{tr}(W_n^\top V_n)$
- Es gilt $-1 \leq \text{NCC} \leq 1$
- Zwei normalisierte Bildsegmente sind sich ähnlich, wenn
 - SSD klein (wenig Unterschiede)
 - NCC nahe bei +1 (hohe Korrelation)

Zusammenfassung

Korrespondenzschätzung von Merkmalspunkten

- Finde Merkmale in Bild 1 und Bild 2
- Kompensiere Rotation durch Ausrichten des Gradienten für jeden Merkmalspunkt
- Extrahiere Bildsegment um jeden Merkmalspunkt
- Beleuchtungskompensation durch Normierung der Bildsegmente
- Vergleiche die normalisierten Bildsegmente durch SSD oder NCC

Martin Kleinsteuber: Computer Vision

Kapitel 2 – Bildentstehung

1. Das Lochkameramodell






Abbildung durch eine dünne Linse



- Strahlen parallel zur optischen Achse werden so gebrochen, dass sie durch die Brennebene gehen
- Strahlen durch das optische Zentrum werden nicht abgelenkt

Abbildung durch eine dünne Linse

Herleitung der Abbildungsgleichung



- $\left| \frac{b}{B} \right| = \frac{z - f}{f}$


- $\left| \frac{z}{Z} \right| = \left| \frac{b}{B} \right|$

- Gleichung für dünne Linsen

$$\frac{1}{|Z|} + \frac{1}{z} = \frac{1}{f}$$

Abbildung durch eine Lochkamera

Idealisierte Annahmen




- Sehr kleine Öffnung vor der Linse
- Beliebig großer Blickwinkel
- Bild wird scharf auf Brennebene abgebildet
- Es gilt:

$$b = -\frac{fB}{Z}$$

Abbildung durch eine Lochkamera


Abbildung eines Punktes im Raum auf die Brennebene



- Koordinaten von P bzgl. optischem Zentrum der Kamera seien (X, Y, Z)
- Dann sind die Koordinaten des Bildpunktes $\left(-\frac{fX}{Z}, -\frac{fY}{Z}, -f\right)$

Frontales Lochkameramodell

Projektion eines Punktes




- Koordinaten des Bildpunktes beim frontalen Lochkameramodell $\left(\frac{fX}{Z}, \frac{fY}{Z}, f\right)$
- Ideale perspektivische Projektion:

$$\pi: \mathbb{R}^3 \setminus \{(X, Y)\text{-Ebene}\} \rightarrow \mathbb{R}^2, \quad \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} \mapsto \frac{f}{Z} \begin{bmatrix} X \\ Y \end{bmatrix}$$

Abbildung durch eine Lochkamera

Idealisierte Annahmen



- Dünne Linse
- Kleine Blende
- Beliebiger großer Blickwinkel
- Perspektivische Projektion:

$$\pi: \mathbb{R}^3 \setminus \{(X, Y)\text{-Ebene}\} \rightarrow \mathbb{R}^2, \quad \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} \mapsto \frac{f}{Z} \begin{bmatrix} X \\ Y \end{bmatrix}$$

Quelle: Wikipedia.de, 2013


Zusammenfassung

- Lochkameramodell
- Ideale perspektivische Projektion:
die Abbildung der Koordinaten des 3D-Punktes auf die 2D-Koordinaten in der Brennebene

Martin Kleinsteuber: Computer Vision

Kapitel 2 – Bildentstehung


2. Homogene Koordinaten



Wiederholung: Lochkameramodell

Bildpunkte und Geraden

- Alle Punkte auf einer Geraden durch das optische Zentrum werden auf denselben Bildpunkt abgebildet
- Umgekehrt existiert zu jedem Bildpunkt genau eine Gerade



Der projektive Raum

- Zwei Vektoren $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ nennen wir zueinander **äquivalent**, falls ein $\lambda \neq 0$ existiert mit $\mathbf{x} = \lambda \mathbf{y}$. In diesem Fall schreiben wir

$$\mathbf{x} \sim \mathbf{y}$$

- Eine Gerade durch $\mathbf{x} \neq 0$ können wir nun beschreiben als **Äquivalenzklasse**


$$[\mathbf{x}] := \{\mathbf{y} \in \mathbb{R}^n \mid \mathbf{y} \sim \mathbf{x}\}$$

- Die Menge aller Geraden im \mathbb{R}^{n+1} heißt **projektiver Raum**

$$\mathbb{P}_n = \{[\mathbf{x}] \mid \mathbf{x} \in \mathbb{R}^{n+1} \setminus \{0\}\}$$

Homogene Koordinaten

- Normiert man die Längeneinheit auf die Brennweite, ist die Bildebene gegeben durch



- Der Vektor $\begin{bmatrix} X \\ Y \\ 1 \end{bmatrix}$ heißt die **homogenen Koordinaten** von $\begin{bmatrix} X \\ Y \end{bmatrix}$

Homogene Koordinaten

- Allgemeine Definition: $\mathbf{x} := (X_1, \dots, X_n)^\top \in \mathbb{R}^n$

Dann heißt

$$\mathbf{x}^{(\text{hom})} := (X_1, \dots, X_n, 1)^\top \in \mathbb{R}^{n+1}$$

die homogenen Koordinaten von \mathbf{x}


Zusammenfassung

- Äquivalente Vektoren unterscheiden sich nur durch Multiplikation mit einer Zahl ungleich Null.
- Homogene Koordinaten eines Vektors erhält man durch Hinzufügen einer weiteren Koordinate mit dem Wert Eins.

Martin Kleinstein: Computer Vision


Kapitel 2 – Bildentstehung

3. Euklidische Bewegungen




Motivation

- Zwei Bilder einer 3D-Szene aus unterschiedlichen Positionen
- Positionswechsel bestehen aus Rotation der Kamera und anschließender Translation
- Beschreibung der Kamerabewegung in Form von Koordinatenänderung eines festen Raumpunktes




Visualisierung

Translation



Visualisierung

Rotation



Euklidische Bewegungen

Allgemein

- Die Matrizen $O(n) := \{O \in \mathbb{R}^{n \times n} \mid O^\top O = I_n\}$ heißen orthogonale Matrizen
- Rotationen im \mathbb{R}^n werden beschrieben durch die speziellen orthogonalen Matrizen
 $SO(n) := \{R \in \mathbb{R}^{n \times n} \mid R^\top R = I_n, \det(R) = 1\}$

- Euklidische Bewegungen durch die Koordinatenänderung

$$g_{R,T}: \mathbb{R}^n \rightarrow \mathbb{R}^n, \quad \mathbf{P} \mapsto R\mathbf{P} + T$$

- Seien \mathbf{P}_1 die Koordinaten eines Punktes bzgl. CF 1 und \mathbf{P}_2 die Koordinaten des selben Punktes bzgl. des bewegten CF 2, dann ist $\mathbf{P}_2 = R\mathbf{P}_1 + T$

Euklidische Bewegungen

In homogenen Koordinaten

- In homogenen Koordinaten als Matrix-Vektor-Multiplikation

$$M = \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix} \in \mathbb{R}^{(n+1) \times (n+1)}, \quad R \in SO(n), T \in \mathbb{R}^n$$

$$\mathbf{P}_2^{(\text{hom})} = M \mathbf{P}_1^{(\text{hom})}$$

- Spezielle Euklidische Gruppe

$$SE(n) = \left\{ M = \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix} \mid R \in SO(n), T \in \mathbb{R}^n \right\} \subset \mathbb{R}^{(n+1) \times (n+1)}$$

Euklidische Bewegungen

Eigenschaften

- Verknüpfungen zweier eukl. Bewegungen ist wieder eine eukl. Bewegung

$$M_1 M_2 = \begin{bmatrix} R_1 & T_1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} R_2 & T_2 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} R_1 R_2 & R_1 T_2 + T_1 \\ 0 & 1 \end{bmatrix}$$

- Euklidische Bewegungen sind invertierbar:


$$M^{-1} = \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix}^{-1} = \begin{bmatrix} R^\top & -R^\top T \\ 0 & 1 \end{bmatrix}$$

Das Kreuzprodukt

Definition

- Das Kreuzprodukt zwischen den Vektoren $\mathbf{u}, \mathbf{v} \in \mathbb{R}^3$ ist definiert als

$$\mathbf{u} \times \mathbf{v} = \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} \times \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} u_2 v_3 - u_3 v_2 \\ u_3 v_1 - u_1 v_3 \\ u_1 v_2 - u_2 v_1 \end{bmatrix} \in \mathbb{R}^3$$




- Es gilt: $\langle \mathbf{u} \times \mathbf{v}, \mathbf{u} \rangle = \langle \mathbf{u} \times \mathbf{v}, \mathbf{v} \rangle = 0$ und $\mathbf{u} \times \mathbf{v} = -\mathbf{v} \times \mathbf{u}$

Das Kreuzprodukt

Matrix-Vektor-Multiplikation

- Das Kreuzprodukt lässt sich schreiben als

$$\mathbf{u} \times \mathbf{v} = \hat{\mathbf{u}} \mathbf{v}, \quad \text{mit} \quad \hat{\mathbf{u}} = \begin{bmatrix} 0 & -u_3 & u_2 \\ u_3 & 0 & -u_1 \\ -u_2 & u_1 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 3}$$



- Es gilt (für A invertierbar):

$$\widehat{A\mathbf{v}} = \det(A) A^{-\top} \hat{\mathbf{v}} A^{-1}$$

Euklidische Bewegungen

Eigenschaften Orthogonaler Transformationen

- Orthogonale Transformationen erhalten
Skalarprodukt $\langle \mathbf{u}, \mathbf{v} \rangle = \langle O\mathbf{u}, O\mathbf{v} \rangle$
- Euklidische Transformationen erhalten Abstand
- Spezielle orthogonale Transformationen erhalten
das Kreuzprodukt

$$R\mathbf{u} \times R\mathbf{v} = R(\mathbf{u} \times \mathbf{v})$$


Zusammenfassung

- Kamerabewegungen durch Koordinatenänderung eines festen Raumpunktes
- Koordinatenänderung durch euklidische Bewegungen
- Rotationen durch spezielle orthogonale Matrizen
- Euklidische Bewegung in homogenen Koordinaten durch Matrix-Vektor-Multiplikation

Martin Kleinsteuber: Computer Vision


Kapitel 2 – Bildentstehung

4. Perspektivische Projektion mit kalibrierter Kamera



Perspektivische Projektion

Lochkameramodell



- Abbildung eines Punktes auf den Bildpunkt
$$\begin{bmatrix} x \\ y \end{bmatrix} = \frac{f}{Z} \begin{bmatrix} X \\ Y \end{bmatrix}$$

Perspektivische Projektion

- Die Abhängigkeit der homogenen Koordinaten erhalten wir aus

$$\begin{bmatrix} x \\ y \end{bmatrix} = \frac{f}{Z} \begin{bmatrix} X \\ Y \end{bmatrix}$$

$$Z \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

Perspektivische Projektion

Mit Brennweitenmatrix und generischer Projektionsmatrix

- Definiere $K_f := \begin{bmatrix} f & 0 & 0 \\ 0 & f & 0 \\ 0 & 0 & 1 \end{bmatrix}$, $\Pi_0 := \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$

- Betrachte 3D-Punkt $\mathbf{P}^{(\text{hom})} = \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$ und $\mathbf{x}^{(\text{hom})} = \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$

- Die Perspektivische Projektion ist somit

$$\mathbf{x}^{(\text{hom})} \sim K_f \Pi_0 \mathbf{P}^{(\text{hom})}$$

Die ideale Kamera

Abbildung von Weltkoordinaten auf Bildkoordinaten

- Transformation der homogenen Koordinaten $\mathbf{P}^{(\text{hom})}$ bei euklidischer Bewegung der Kamera


$$\mathbf{P}^{(\text{hom})} = \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix} \mathbf{P}_0^{(\text{hom})} \quad R \in SO(3), \quad T \in \mathbb{R}^3$$

- Perspektivische Projektion mit euklidischer Transformation

$$\mathbf{x}^{(\text{hom})} \sim K_f \Pi_0 \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix} \mathbf{P}_0^{(\text{hom})}$$

Sensorparameter

Transformation von Bildkoordinaten in Pixelkoordinaten



1. Spezifizieren der Längeneinheiten (LE)


- $x_s = s_x x$, gleiches mit $y_s = s_y y$
- $s_x = s_y$ bedeutet quadratische Pixel

2. Justieren des Ursprungs

- Pixelkoordinaten $x' = x_s + o_x$, gleiches mit $y' = y_s + o_y$

Sensorparameter

Lineare Transformation von Bildkoordinaten in Pixelkoordinaten



3. Einführen eines Scherungsfaktors s_θ

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \underbrace{\begin{bmatrix} s_x & s_\theta & o_x \\ 0 & s_y & o_y \\ 0 & 0 & 1 \end{bmatrix}}_{:=K_s} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

$$\mathbf{x}' = K_s \mathbf{x}$$

$$\mathbf{x} = K_s^{-1} \mathbf{x}'$$

Kalibrierungsmatrix

Zusammenführen von Brennweite und Sensorparametern

- Pixelkoordinaten

- Perspektivische Projektion

$$\mathbf{x}' = K_s \mathbf{x} \quad \mathbf{x} \sim K_f \Pi_0 \mathbf{P}$$

$$\mathbf{x}' \sim K_s K_f \Pi_0 \mathbf{P} = \underbrace{\begin{bmatrix} s_x & s_\theta & o_x \\ 0 & s_y & o_y \\ 0 & 0 & 1 \end{bmatrix}}_{:=K} \underbrace{\begin{bmatrix} f & 0 & 0 \\ 0 & f & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{\Pi_0} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

- Kalibrierungsmatrix (intrinsische Kameraparameter)

$$K = K_s K_f = \begin{bmatrix} f s_x & f s_\theta & o_x \\ 0 & f s_y & o_y \\ 0 & 0 & 1 \end{bmatrix}$$

Zusammenfassung

- Abbildung von Weltkoordinaten auf Pixelkoordinaten durch

$$\mathbf{x}' \sim K \Pi_0 \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix} \mathbf{P}_0$$

- Intrinsische Parameter K :
- Extrinsische Parameter: Position der Kamera
- Umrechnung von idealen Bildkoordinaten und Pixelkoordinaten

$$\mathbf{x}' = K_s \mathbf{x}$$


$$\mathbf{x} = K_s^{-1} \mathbf{x}'$$



Martin Kleinsteuber: Computer Vision

Kapitel 2 – Bildentstehung

5. Bild, Urbild und Cobild



Motivation



Wiederholung

Projektion von Geraden

- Gerade im Raum in homogenen Koordinaten

$$L^{(\text{hom})} = \left\{ \mathbf{P}_0^{(\text{hom})} + \lambda [v_1, v_2, v_3, 0]^T \mid \lambda \in \mathbb{R} \right\}$$

- Perspektivische Projektion einer Geraden – Beispiel




Bild und Urbild

Definitionen

- Das Bild eines Punktes bzw. einer Geraden ist deren perspektivische Projektion

$$\Pi_0 \mathbf{P}^{(\text{hom})} \quad \text{bzw.} \quad \Pi_0 L^{(\text{hom})}$$

- Das Urbild eines Punktes \mathbf{P} bzw. einer Geraden L sind alle Punkte im Raum, die auf den gleichen Bildpunkt bzw. auf die gleiche Gerade in der BE projiziert werden.


$$\text{Urbild}(\mathbf{P}) = \{ \mathbf{Q} \in \mathbb{R}^3 \mid \Pi_0 \mathbf{Q}^{(\text{hom})} \sim \Pi_0 \mathbf{P}^{(\text{hom})} \}$$

$$\text{Urbild}(L) = \bigcup_{\mathbf{P} \in L} \text{Urbild}(\mathbf{P})$$

Bild und Urbild

Eigenschaften

- Urbilder von Punkten sind Geraden durch den Ursprung
- Urbilder von Geraden sind Ebenen durch den Ursprung



Exkurs: Lineare Algebra

Erzeugnis und Orthogonales Komplement


- Erzeugnis von Spaltenvektoren \mathbf{a}_i einer Matrix $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_m] \in \mathbb{R}^{n \times m}$

$$\text{span}(\mathbf{A}) = \left\{ \sum_{i=1}^m \lambda_i \mathbf{a}_i \mid \lambda_i \in \mathbb{R} \right\}$$

- Das Erzeugnis ist ein Untervektorraum vom \mathbb{R}^n

- Orthogonales Komplement eines Untervektorraums


$$\text{span}(\mathbf{A})^\perp = \{ \mathbf{v} \in \mathbb{R}^n \mid \langle \mathbf{a}_i, \mathbf{v} \rangle = 0, i = 1, \dots, m \}$$



Exkurs: Lineare Algebra

Dimension, Kern und Rang



- Dimension eines Untervektorraums:
Anzahl der Elemente eines minimalen Erzeugendensystems
- Rang einer Matrix ist Dimension des Erzeugnisses der Spalten
- Kern einer Matrix $\mathbf{A} \in \mathbb{R}^{n \times m}$
 $\text{Ker}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^m \mid \mathbf{A}\mathbf{x} = \mathbf{0}\}$
- $\text{Ker}(\mathbf{A})$ ist Untervektorraum im \mathbb{R}^m
- Dimensionssatz:
 $\mathbf{A} \in \mathbb{R}^{n \times m}$
 $\text{Rang}(\mathbf{A}) + \dim \text{Ker}(\mathbf{A}) = m$



Cobild

Definition

- Das Cobild von Punkten oder Geraden ist das orthogonale Komplement des Urbildes





Bild, Urbild und Cobild

Zusammenhänge

- Äquivalente Darstellung von Bild, Urbild und Cobild

| | Bild | Urbild | Cobild |
|-------|--|---------------------------|---------------------------------|
| Punkt | $\text{span}(\mathbf{P}) \cap \text{BE}$ | $\text{span}(\mathbf{P})$ | $\text{span}(\hat{\mathbf{P}})$ |
| Linie | $\text{span}(\hat{\ell}) \cap \text{BE}$ | $\text{span}(\hat{\ell})$ | $\text{span}(\ell)$ |



Cobild


Nützliche Eigenschaften

- Sei L eine Gerade im Raum mit $\ell \in \text{Cobild}(L)$ und sei \mathbf{x} das Bild eines Punktes auf dieser Linie. Dann gilt:

$$\mathbf{x}^\top \ell = \ell^\top \mathbf{x} = 0$$

- Seien \mathbf{x}_1 und \mathbf{x}_2 Bilder zweier Punkte im Raum. Dann gilt für das Cobild ℓ der Verbindungsgeraden:

$$\ell \sim \mathbf{x}_1 \times \mathbf{x}_2$$




Cobild

Nützliche Eigenschaften

- Seien ℓ_1 und ℓ_2 die Cobilder zweier Geraden.
Dann gilt für den Schnittpunkt \mathbf{x}
der Bilder dieser Geraden:

$$\mathbf{x} \sim \ell_1 \times \ell_2$$



Kollinearität von Bildpunkten

Untersuchung mit Hilfe des Ranges

- Die Bildpunkte $\mathbf{x}_1, \dots, \mathbf{x}_n$ liegen genau dann auf einer Linie (sind kollinear), wenn

$$\text{Rang}([\mathbf{x}_1, \dots, \mathbf{x}_n]) \leq 2$$

Allgemein sind für $\mathbf{A} \in \mathbb{R}^{n \times n}$ äquivalent:

- $\det \mathbf{A} = 0$
- $\text{Rang}(\mathbf{A}) < n$

Kollinearität von Bildpunkten

Untersuchung mit Hilfe des Ranges

- Die Bildpunkte $\mathbf{x}_1, \dots, \mathbf{x}_n$ liegen genau dann auf einer Linie (sind kollinear), wenn

$$\text{Rang}([\mathbf{x}_1, \dots, \mathbf{x}_n]) \leq 2$$

- Drei Bildpunkte sind genau dann kollinear, wenn

$$\det[\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3] = 0$$

Allgemein sind für $\mathbf{A} \in \mathbb{R}^{n \times n}$ äquivalent:

- $\det \mathbf{A} = 0$
- $\text{Rang}(\mathbf{A}) < n$

Eigenwerte und Eigenvektoren

Diagonalisierbarkeit von Matrizen

- Eigenwerte und Eigenvektoren einer Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v} \quad \text{falls} \quad \exists \mathbf{v} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$$

- Eigenvektoren sind nur bis auf Skalierung bestimmt

$$\alpha \mathbf{A}\mathbf{v} = \alpha \lambda \mathbf{v}$$

- Manche Matrizen $\mathbf{A} \in \mathbb{R}^{n \times n}$ sind diagonalisierbar, d.h.

$$\exists \mathbf{S} \in \mathbb{R}^{n \times n}, \mathbf{S} \text{ invertierbar} \quad \mathbf{D}_A = \mathbf{S}^{-1} \mathbf{A} \mathbf{S}$$

- Reelle symmetrische Matrizen sind diagonalisierbar und haben zueinander orthogonale Eigenvektoren, d.h.

$$\mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_n], \mathbf{v}_i \text{ EV von } \mathbf{A} \quad \mathbf{D}_A = \mathbf{V}^\top \mathbf{A} \mathbf{V}$$

Positiv (semi-)definite Matrizen

Orthogonale Diagonalisierbarkeit

- Eine symmetrische Matrix $\mathbf{A} = \mathbf{A}^\top$ heißt positiv (semi-)definit, wenn $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$, $\mathbf{x} \neq \mathbf{0}$
- Die Eigenwerte positiv (semi-)definiter Matrizen sind positiv (nicht negativ)
- Also können positiv (semi-)definite Matrizen orthogonal diagonalisiert werden, d.h.

$$\lambda_i \geq 0, \forall \lambda_i \text{ EW von } \mathbf{A}$$

$$\mathbf{D}_A = \mathbf{V}^\top \mathbf{A} \mathbf{V} \quad \mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_n], \mathbf{v}_i \text{ EV von } \mathbf{A}$$

Kollinearität von Bildpunkten

Untersuchung mit Hilfe der Eigenwerte

- Die Bildpunkte $\mathbf{x}_1, \dots, \mathbf{x}_n$ liegen genau dann auf einer Linie (sind kollinear), wenn
- Drei Bildpunkte sind genau dann kollinear, wenn
- Die Bildpunkte $\mathbf{x}_1, \dots, \mathbf{x}_n$ sind genau dann kollinear, wenn der kleinste Eigenwert von

$$\mathbf{M} = \sum_{i=1}^n \omega_i \mathbf{x}_i \mathbf{x}_i^\top$$

gleich null ist $\forall \omega_i > 0$

Aspekte bei der praktischen Umsetzung

Ungenauigkeiten durch Diskretisierung / Rauschen

- In der Praxis sind die Bedingungen
 - $\det[\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3] = 0$
 - Kleinster Eigenwert von $\mathbf{M} = \sum_{i=1}^n \omega_i \mathbf{x}_i \mathbf{x}_i^T$ ist gleich null
nicht erfüllt
- Verwendung von Schwellwerten


Zusammenfassung

- Urbilder von Punkten und Geraden sind Untervektorräume
- Cobild ist das orthogonale Komplement des Urbildes
- Darstellung von Linien im Bild mittels Cobildes
- Kriterien zur Kollinearität von Punkten
- Bild, Urbild und Cobild sind nützlicher Formalismus zum Erklären von einfachen geometrischen Zusammenhängen von Punkten und Geraden im Raum und auf der Bildebene


Martin Kleinsteuber: Computer Vision

Kapitel 3 – Epipolargeometrie

1. Epipolargleichung




Motivation



- Ziel: Zusammenhang zwischen korrespondierenden Bildpunkten in Abhängigkeit der euklidischen Bewegung der Kamera beschreiben

Epipolargeometrie

Überblick und Notation



Euklidische Bewegung

Umrechnung von Kamera 1 in Kamera 2

- \mathbf{P}_1 sind die Koordinaten des Punktes \mathbf{P} in Kamerasystem 1
- \mathbf{P}_2 sind die Koordinaten des Punktes \mathbf{P} in Kamerasystem 2
- Euklidische Bewegung der Kameras beschrieben durch die Koordinatentransformation

$$\mathbf{P}_2 = R\mathbf{P}_1 + T$$

mit $R \in SO(3), T \in \mathbb{R}^3$

Perspektivische Projektion

Zusammenhang zwischen Punkten und Bildpunkten


- Unter Annahme einer idealen Kamera gilt

$$\lambda_i \mathbf{x}_i = \mathbf{P}_i, \quad i = 1, 2, \quad \lambda \in \mathbb{R}$$

- Einsetzen in Euklidische Bewegung

$$\lambda_2 \mathbf{x}_2 = R \lambda_1 \mathbf{x}_1 + T$$

- Problem: Die Skalierungsfaktoren λ_i sind im Allgemeinen unbekannt



Die Epipolargleichung

Formeller Zusammenhang zwischen korrespondierenden Bildpunkten

$$\lambda_2 \mathbf{x}_2 = R \lambda_1 \mathbf{x}_1 + T$$

- Die Matrix $E = \hat{T}R$ heißt *essentielle Matrix* zur euklidischen Bewegung (R, T)
- Epipolargleichung $\mathbf{x}_2^\top E \mathbf{x}_1 = 0$

Eigenschaften der essentiellen Matrix Singulärwertzerlegung

- Jede Matrix $A \in \mathbb{R}^{n \times m}$ lässt sich schreiben als Produkt

$$A = U \tilde{\Sigma} V^T$$

wobei $U \in O(n), V \in O(m)$ und

- $n \leq m$: $\tilde{\Sigma} = \begin{bmatrix} \Sigma & | 0 \end{bmatrix}$

- $m < n$: $\tilde{\Sigma} = \begin{bmatrix} \Sigma \\ 0 \end{bmatrix}$

- $\Sigma = \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_{\min\{n,m\}} & \\ & & & 0 \end{bmatrix} \quad \sigma_1 \geq \sigma_2 \geq \dots \geq 0$

Eigenschaften der essentiellen Matrix Singulärwertzerlegung

- Singulärwerte einer Matrix sind eindeutig bestimmt. U und V in der Regel nicht.

- Zusammenhang mit der Eigenwertzerlegung von AA^T und $A^T A$:

Eigenschaften der essentiellen Matrix

Charakterisierung durch Singulärwertzerlegung

- Eine Matrix E ist genau dann eine essentielle Matrix, also von der Form $E = \hat{T}R$ mit schiefsymmetrischem \hat{T} und Rotationsmatrix R , wenn für die Singulärwertzerlegung von E gilt:

$$E = U \begin{bmatrix} \sigma & & \\ & \sigma & \\ & & 0 \end{bmatrix} V^{\top}$$


Zusammenfassung

- Epipolargleichung beschreibt Zusammenhang zwischen korrespondierenden Bildpunkten aus unterschiedlichen Aufnahmen
- Die essentielle Matrix enthält die Information aus der euklidischen Bewegung
- Essentielle Matrizen sind genau die mit zwei gleichen Singulärwerten und einem Singulärwert gleich null

Martin Kleinsteuber: Computer Vision


Kapitel 3 – Epipolargeometrie

2. Epipole und Epipolarlinien



Epipolargeometrie


Wiederholung Epipolargleichung



Epipolargeometrie

Definition der Epipole

- Die perspektivischen Projektionen der optischen Zentren in das jeweils andere Kamerasystem heißen **Epipole**



Epipole

Eigenschaften

- Aus Geometrie der eukl. Bewegung: $e_1 \sim R^T T$, $e_2 \sim T$
- e_1 liegt im Kern von E : $E e_1 = 0$
- e_2 liegt im Kern von E^T : $E^T e_2 = 0$

Die Nullräume von E aus der Singulärwertzerlegung

$$\blacksquare E = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \mathbf{u}_3] \begin{bmatrix} \sigma & 0 & 0 \\ 0 & \sigma & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{v}_1^\top \\ \mathbf{v}_2^\top \\ \mathbf{v}_3^\top \end{bmatrix}$$

$$\blacksquare \mathbf{e}_1 \sim \mathbf{v}_3 \Rightarrow E\mathbf{e}_1 = 0$$

- Das Urbild von \mathbf{e}_1 ist äquivalent zum dritten rechtsseitigen Singulärvektor von E

Die Nullräume von E^\top aus der Singulärwertzerlegung

$$\blacksquare E^\top = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \mathbf{v}_3] \begin{bmatrix} \sigma & 0 & 0 \\ 0 & \sigma & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{u}_1^\top \\ \mathbf{u}_2^\top \\ \mathbf{u}_3^\top \end{bmatrix}$$


$$\blacksquare \mathbf{e}_2 \sim \mathbf{u}_3 \Rightarrow E^\top \mathbf{e}_2 = 0$$

- Das Urbild von \mathbf{e}_2 ist äquivalent zum dritten linksseitigen Singulärvektor von E

Epipolargeometrie

Definition Epipolarebene und Epipolarlinie

- Die Ebene, die durch O_1 , O_2 und P aufgespannt wird, heißt **Epipolarebene von P**
- Der Schnitt der Epipolarebene mit der Bildebene heißt **Epipolarlinie**




Epipolarlinien

Geometrische Interpretation

- Die Epipolarlinie ist das Bild, das vom Urbild eines Punktes im anderen Kamerasystem erzeugt wird.
- Die Epipolarebene wird von den Ortsvektoren des Bildpunktes und des Epipols aufgespannt: $\text{span}(\mathbf{x}_i, \mathbf{e}_i)$
- Epipolarlinie wird über Cobild identifiziert


$$\ell_i \sim \mathbf{e}_i \times \mathbf{x}_i$$



Epipolarlinien

Eigenschaften


- $\ell_i^\top \mathbf{x}_i = 0, \quad \ell_i^\top \mathbf{e}_i = 0$
- $\ell_1 \sim E^T \mathbf{x}_2, \quad \ell_2 \sim E \mathbf{x}_1$



Korrespondenzsuche

mit Hilfe der essentiellen Matrix

- Gegeben: E und \mathbf{x}_1
- Berechne $\ell_2 \sim E \mathbf{x}_1$
- Bestimme das Bild der Epipolarlinie
- Suche (z.B. mit NCC) entlang des Bildes nach \mathbf{x}_2




Zusammenfassung

- Berechnung der Epipole und Epipolarlinien mit Hilfe der essentiellen Matrix
- Urbilder der Epipole aus Singulärwertzerlegung der essentiellen Matrix
- Epipolarlinie mittels $\ell_2 \sim E\mathbf{x}_1$
- Vereinfachte Suche nach Korrespondenzen mit Epipolarlinie


Martin Kleinsteuber: Computer Vision

Kapitel 3 – Epipolargeometrie

3. Der 8-Punkt-Algorithmus



Motivation



- Euklidische Bewegung nicht bekannt
- Korrespondenzen von Merkmalspunkten bekannt
- Wie schätzt man die essentielle Matrix?

8-Punkt-Algorithmus zur Schätzung der Essentiellen Matrix

Motivation / Voraussetzungen

- Gegeben: n Korrespondenzpunktpaare $(\mathbf{x}_1^j, \mathbf{x}_2^j)$
- Idealerweise erfüllen alle KP die Epipolargleichung

$$\mathbf{x}_2^{j\top} E \mathbf{x}_1^j = 0$$
- Ziel: Berechne die essentielle Matrix E aus den geschätzten KP
 $E \in \mathbb{R}^{3 \times 3}$, somit 9 Unbekannte
- Skalierungsinvarianz: Wenn E Lösung ist, dann auch
 $\lambda E, \quad \lambda \in \mathbb{R}$
- Benötige 8 unabhängige Gleichungen

Vektorisierte Epipolargleichung

- Bislang: $\mathbf{x}_2^j \top E \mathbf{x}_1^j = 0$

- Für ein ideales Korrespondenzpunktpaar $(\mathbf{x}_1^j, \mathbf{x}_2^j)$ gilt somit

$$\mathbf{a}^j \top \mathbf{E}^s = 0$$

Kronecker-Produkt \otimes

$$\mathbf{x}_1 = \begin{bmatrix} x_1 \\ y_1 \\ z_1 \end{bmatrix} \quad \mathbf{x}_2 = \begin{bmatrix} x_2 \\ y_2 \\ z_2 \end{bmatrix} \quad \mathbf{a} := \mathbf{x}_1 \otimes \mathbf{x}_2 = \begin{bmatrix} x_1 x_2 \\ x_1 y_2 \\ x_1 z_2 \\ y_1 x_2 \\ y_1 y_2 \\ y_1 z_2 \\ z_1 x_2 \\ z_1 y_2 \\ z_1 z_2 \end{bmatrix} \in \mathbb{R}^9$$

Vektorisieren („stacking“)

$$E = \begin{bmatrix} e_{11} & e_{12} & e_{13} \\ e_{21} & e_{22} & e_{23} \\ e_{31} & e_{32} & e_{33} \end{bmatrix} \quad \text{ergibt} \quad \mathbf{E}^s = \begin{bmatrix} e_{11} \\ e_{21} \\ e_{31} \\ e_{12} \\ e_{22} \\ e_{32} \\ e_{13} \\ e_{23} \\ e_{33} \end{bmatrix}$$

Der 8-Punkt-Algorithmus

Gleichungssystem zur Bestimmung von E

- Aus n Korrespondenzpunktpaaren ergibt sich das homogene lineare Gleichungssystem $A \mathbf{E}^s = 0$, mit
- Für generisch verteilte ideale KP gilt $\dim(\text{kern}(A)) = 1$ und somit $\text{rk}(A) = 8$

$$A := \begin{bmatrix} \mathbf{a}^1 \top \\ \mathbf{a}^2 \top \\ \vdots \\ \mathbf{a}^n \top \end{bmatrix} \in \mathbb{R}^{n \times 9}$$

- Durch Diskretisierungsfehler gilt in der Realität $\text{rk}(A) = 9$

- Für $n > 8$ hat das homogene LGS keine nicht-triviale Lösung

Exkurs: Lineare Algebra

Homogene Gleichungssysteme

- Idee: Statt $A\mathbf{x} = 0$ wird Minimierungsproblem gelöst

$$\min_{\mathbf{x}} \|A\mathbf{x}\|_2^2$$

- Da Lösungen skalierungsinvariant sind, kann die Suche beschränkt werden auf

$$\mathbf{x} : \|\mathbf{x}\|_2 = 1$$

- Also finde \mathbf{x} mit $\|\mathbf{x}\|_2 = 1$, welches $\|A\mathbf{x}\|_2^2$ minimiert.

Exkurs: Lineare Algebra

Lösung des Minimierungsproblems mittels SVD

- Singulärwertzerlegung $A = U\Sigma V^T$

$$= \mathbf{x}^T V \begin{bmatrix} \sigma_1^2 & & & \\ & \sigma_2^2 & & \\ & & \ddots & \\ & & & \sigma_n^2 \end{bmatrix} V^T \mathbf{x}$$

- $\mathbf{v}_n = \arg \min_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2^2$

Der 8-Punkt-Algorithmus

Bisherige Herleitung

- Bilde Matrix A aus $n \geq 8$ generisch gelegenen Korrespondenzpunktpaaren

- Löse Minimierungsproblem $\mathbf{G}^s = \arg \min_{\|\mathbf{E}^s\|_2=1} \|\mathbf{A}\mathbf{E}^s\|_2^2$:

Singulärwertzerlegung $A = U_A \Sigma_A V_A^\top$ liefert die Lösung

$$\mathbf{G}^s = \mathbf{v}_9 \quad (9. \text{ Spalte von } V_A)$$

- Umsortieren der Einträge von \mathbf{G}^s führt zu $G \in \mathbb{R}^{3 \times 3}$

Der 8-Punkt-Algorithmus


Von der Lösung des Minimierungsproblems zur Essentiellen Matrix

- G ist in der Regel keine essentielle Matrix
- Projektion auf den Raum der essentiellen Matrizen \mathcal{E}

$$G = U_G \Sigma_G V_G^\top \quad \Sigma_G = \begin{bmatrix} \sigma_1 & & \\ & \sigma_2 & \\ & & \sigma_3 \end{bmatrix}$$

- Finde die „nächste“ essentielle Matrix zu G

$$E = \arg \min_{E \in \mathcal{E}} \|E - G\|_F^2$$



Der 8-Punkt-Algorithmus

Projektion auf die nächste Essentielle Matrix

- $E = \arg \min_{E \in \mathcal{E}} \|E - G\|_F^2$

- E kann nur bis auf Skalierung geschätzt werden

- $E = U_G \begin{bmatrix} \sigma & & \\ & \sigma & \\ & & 0 \end{bmatrix} V_G^\top$

- In der Praxis daher üblicherweise

$$E = U_G \begin{bmatrix} 1 & & \\ & 1 & \\ & & 0 \end{bmatrix} V_G^\top$$

- $\sigma = \frac{\sigma_1 + \sigma_2}{2}$

Zusammenfassung


8-Punkt-Algorithmus

- Lineares Gleichungssystem aus Epipolarbedingungen
- Koeffizientenmatrix aus Kroneckerprodukt der KP-Paare
- Lösung ist der 9. rechtsseitige Singulärvektor
- Projektion auf normierte essentielle Matrizen
 - Singulärwertzerlegung der umsortierten Lösung
 - Zu-Eins-Setzen der ersten beiden Singulärwerte
 - Zu-Null-Setzen des kleinsten Singulärwerts

Martin Kleinsteuber: Computer Vision

Kapitel 3 – Epipolargeometrie


4. 3D-Rekonstruktion



3D-Rekonstruktion

Motivation und Annahmen

- Ziel: Schätze die euklidische Bewegung (R, \mathbf{T}) aus der essentiellen Matrix und rekonstruiere 3D-Punkte aus Punktkorrespondenzen $(\mathbf{x}_1^j, \mathbf{x}_2^j)$



Rekonstruktion von Rotation und Translation mit Singulärwertzerlegung der essentiellen Matrix

- Benötige $E = U\Sigma V^\top$, $U, V \in SO(3)$ (Rotationsmatrizen mit Determinante 1)
- SVD nicht eindeutig, U und V nicht zwangsläufig Rotationsmatrizen
- Beispiel: $\det(U) = -1$

$$E = U \begin{bmatrix} \sigma & & \\ & \sigma & \\ & & 0 \end{bmatrix} V^\top$$

Rekonstruktion von Rotation und Translation mit Singulärwertzerlegung der essentiellen Matrix

- Gegeben: $E = U\Sigma V^\top$, $U, V \in SO(3)$
- Man kann zeigen, dass mit den Matrizen

$$R_Z(\pm\frac{\pi}{2}) = \begin{bmatrix} 0 & \mp 1 & 0 \\ \pm 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \text{ gilt:}$$

$$R = UR_Z^\top(\pm\frac{\pi}{2})V^\top$$

$$\hat{T} = UR_Z(\pm\frac{\pi}{2})\Sigma U^\top$$

Rekonstruktion von Rotation und Translation

Mehrdeutigkeiten

- 8-Punkt-Algorithmus liefert $\pm E$
- Je zwei Lösungen für (R, \hat{T})
- Insgesamt 4 euklidische Transformationen, welche die Korrespondenzen erklären
- Nur eine Transformation geometrisch plausibel
- \mathbf{T} aus \hat{T} nur bis auf Skalierung bestimmbar

Rekonstruktion der 3D-Koordinaten

aus geschätzter euklidischer Transformation

- Ziel: Schätze die Tiefe der Raumpunkte,
z.B. λ_1^j in Kamerasystem 1
- $\lambda_2^j \mathbf{x}_2^j = \lambda_1^j R \mathbf{x}_1^j + \gamma \mathbf{T}, \quad j = 1, 2, \dots, n$
- Jedes Korrespondenzpunktpaar liefert

$$\underbrace{\begin{bmatrix} \widehat{\mathbf{x}_2^j R \mathbf{x}_1^j} & \widehat{\mathbf{x}_2^j \mathbf{T}} \end{bmatrix}}_{:= M^j} \begin{bmatrix} \lambda_1^j \\ \gamma \end{bmatrix} = 0$$


Rekonstruktion der 3D-Koordinaten bis auf Skalierung möglich

■ Ideale KP erfüllen $M\mathbf{d} := \begin{bmatrix} \widehat{\mathbf{x}}_2^1 R \mathbf{x}_1^1 & \widehat{\mathbf{x}}_2^1 \mathbf{T} \\ \widehat{\mathbf{x}}_2^2 R \mathbf{x}_1^2 & \widehat{\mathbf{x}}_2^2 \mathbf{T} \\ \vdots & \vdots \\ \widehat{\mathbf{x}}_2^n R \mathbf{x}_1^n & \widehat{\mathbf{x}}_2^n \mathbf{T} \end{bmatrix} \begin{bmatrix} \lambda_1^1 \\ \lambda_1^2 \\ \vdots \\ \lambda_1^n \\ \gamma \end{bmatrix} = 0$

- In der Praxis: Löse Minimierungsproblem $\min_{\|\mathbf{d}\|_2=1} \|M\mathbf{d}\|_2^2$ über SVD von M
- Inhärente Skalierungsinvarianz: Ohne weiteres Wissen über die Szene keine Unterscheidung zwischen Skalierung des Objektes und Distanz der Kamera
- Geschätzte 3D-Koordinaten von \mathbf{P} bzgl. Kamerasystems 1 sind $\mathbf{P}_1^j = \lambda_1^j \mathbf{x}_1^j$

Rekonstruktion der 3D-Koordinaten Schwierigkeiten und Lösungsansätze

- Fehlerhafte Korrespondenzschätzung
 - Lösung z.B. über RanSaC-Methode
- Fehlerhafte 3D-Rekonstruktion durch Diskretisierungsfehler
 - Zusätzliche Schätzung von λ_2^j
 - Robuste Triangulationsverfahren, die 8PA als Initialisierung verwenden.




Zusammenfassung

- Zwei euklidische Transformationen zu einer essentiellen Matrix
- Vier euklidische Transformationen nach 8-Punkt-Algorithmus
- Physikalisch richtige durch Überprüfen der Positivität der Tiefen
- Rekonstruktion der 3D-Raumkoordinaten mittels euklidischer Transformation

Martin Kleinsteuber: Computer Vision

Kapitel 3 – Epipolargeometrie

5. Die Fundamentalmatrix



Motivation

- Epipolargleichung für kalibrierte Kameras $\mathbf{x}_2^\top E \mathbf{x}_1 = 0$
- Kann man eine ähnliche Beziehung zwischen Pixelkoordinaten im unkalibrierten Fall finden?
- Beziehung zwischen kalibrierten und unkalibrierten Koordinaten ergibt sich aus der Matrix K

$$\mathbf{x}' \sim K \Pi_0 \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix} \mathbf{P}$$

$$\mathbf{x} = K^{-1} \mathbf{x}' \sim \Pi_0 \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix} \mathbf{P}$$

$$K = K_s K_f = \begin{bmatrix} f s_x & f s_\theta & o_x \\ 0 & f s_y & o_y \\ 0 & 0 & 1 \end{bmatrix}$$

Epipolargleichung Unkalibrierter Fall


- Epipolargleichung für kalibrierte Kameras $\mathbf{x}_2^\top E \mathbf{x}_1 = 0$
- Unkalibrierte Version der Epipolargleichung:

$$\mathbf{x}_2'^\top K^{-\top} E K^{-1} \mathbf{x}_1' = 0$$
- Die Matrix $F := K^{-\top} E K^{-1}$ heißt Fundamentalmatrix.

Epipolargeometrie

Unkalibrierter Fall

- Euklidische Transformation $\lambda_2 \mathbf{x}_2 = R \lambda_1 \mathbf{x}_1 + T$




- Es gilt $\mathbf{x}_2'^T \hat{T}' K R K^{-1} \mathbf{x}_1' = 0$
- Mit $\hat{T}' \sim K^{-T} \hat{T} K^{-1}$ folgt $F \sim \hat{T}' K R K^{-1}$

Eigenschaften der Fundamentalmatrix

Epipole und Epipolarlinien

- Der Korrespondenzpunkt \mathbf{x}_2' liegt auf der Linie $\ell_2' \sim F \mathbf{x}_1'$ und umgekehrt: \mathbf{x}_1' liegt auf $\ell_1' \sim F^T \mathbf{x}_2'$



- Die Epipole in Pixelkoordinaten:

$$\mathbf{e}_2'^T F = 0, \quad F \mathbf{e}_1' = 0$$

Eigenschaften der Fundamentalmatrix

Singulärwertzerlegung der Fundamentalmatrix

- Eine Matrix ist genau dann eine Fundamentalmatrix wenn für ihre Singulärwertzerlegung gilt:

$$F = U\Sigma V^\top \quad \text{mit} \quad \Sigma = \begin{bmatrix} \sigma_1 & & \\ & \sigma_2 & \\ & & 0 \end{bmatrix}$$

- Fundamentalmatrix kann über den 8-Punkt-Algorithmus geschätzt werden

Eigenschaften der Fundamentalmatrix

8-Punkt-Algorithmus zum Schätzen der Fundamentalmatrix

- Gegeben: n Korrespondenzpunktpaare in Pixelkoordinaten $(\mathbf{x}_1'^j, \mathbf{x}_2'^j), j = 1, \dots, n \quad (n \geq 8)$
- Bilde Koeffizientenmatrix $A := \begin{bmatrix} \mathbf{a}^1 \top \\ \vdots \\ \mathbf{a}^n \top \end{bmatrix} \in \mathbb{R}^{n \times 9}$ mit $\mathbf{a}^j = \mathbf{x}_1'^j \otimes \mathbf{x}_2'^j$
- Extrahiere rechtsseitigen Singulärvektor von A zum kleinsten Singulärwert und konstruiere daraus eine Matrix $G \in \mathbb{R}^{3 \times 3}$
- Projiziere auf die Menge der Fundamentalmatrizen:
 - SVD von $G = U_G \text{diag}\{\sigma_1, \sigma_2, \sigma_3\} V_G^\top$
 - Schätzung der Fundamentalmatrix $F = U_G \text{diag}\{\sigma_1, \sigma_2, 0\} V_G^\top$

Kalibrierter vs. Unkalibrierter Fall Überblick & Diskussion

Kalibrierte Kamera

- Epipolargleichung $\mathbf{x}_2^\top E \mathbf{x}_1 = 0$
- Essentielle Matrix $E = \hat{T}R$
- Epipole und Epipolarlinien

$$E \mathbf{e}_1 = 0, \quad E^\top \mathbf{e}_2 = 0$$

$$\ell_2 \sim E \mathbf{x}_1, \quad \ell_1 \sim E^\top \mathbf{x}_2$$

- 3D-Rekonstruktion möglich

Unkalibrierte Kamera

- Epipolargleichung $\mathbf{x}_2'^\top F \mathbf{x}_1' = 0$
- Fundamentalmatrix $F = K^{-\top} \hat{T} R K^{-1}$
- Epipole und Epipolarlinien

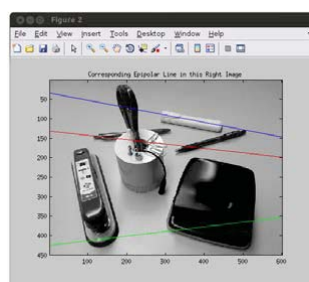
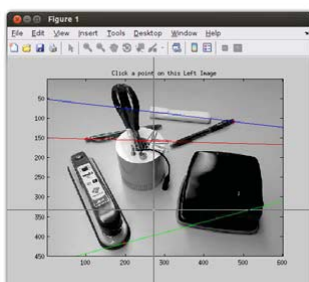
$$F \mathbf{e}_1' = 0, \quad F^\top \mathbf{e}_2' = 0$$

$$\ell_2' \sim F \mathbf{x}_1', \quad \ell_1' \sim F^\top \mathbf{x}_2'$$

- 3D-Rekonstruktion nicht ohne Weiteres möglich

MATLAB-Demonstration 8-Punkt-Algorithmus und Epipolarlinien

- Mitul Saha & Rohit Singh, Stanford University
- <http://ai.stanford.edu/~mitul/cs223b/fm.html>




Zusammenfassung

- Epipolargleichung für unkalibrierte Kamera
- Fundamentalmatrix beinhaltet Information der intrinsischen Kameraparameter und der euklidischen Bewegung
- Schätzen der Fundamentalmatrix mit dem 8-Punkt-Algorithmus und Korrespondenzpunkten in Pixelkoordinaten

Martin Kleinstеuber: Computer Vision

Kapitel 4 – Planare Szenen

1. Die planare Epipolargleichung



Motivation

Planare Szene (Luftbild)



© 2013 DigitalGlobe, GeoBasis-DE/BKG, GeoContent, TerraMetrics, Google

- Ziel 1: Formeller Zusammenhang zwischen Korrespondenzen
- Ziel 2: Schätze euklidische Bewegung der Kamera mit Korrespondenzen in einer planaren Szene


Planare Szene Ebenengleichung

- Ebene in Kamerasystem 1

$$\mathcal{H} =: \{\mathbf{X} \in \mathbb{R}^3 \mid \mathbf{n}^\top \mathbf{X} = d\}$$

\mathbf{n} : Normierter Normalenvektor

d : Abstand von \mathcal{H} zu \mathbf{O}_1




- Ebenengleichung mit Hilfe von \mathbf{P}_1

$$\mathbf{n}^\top \mathbf{P}_1 = n_1 X + n_2 Y + n_3 Z = d$$

Planare Epipolargleichung

Zusammenhang zwischen KP in planarer Szene

- Euklidische Bewegung $\mathbf{P}_2 = R\mathbf{P}_1 + T$
- Ebenengleichung $\mathbf{n}^\top \mathbf{P}_1 = d$



- H heißt planare Homographiematrix zur Ebene \mathcal{H} und zur euklidischen Bewegung (R, T)
- Die Gleichung $\mathbf{x}_2 \sim H\mathbf{x}_1$ heißt planare Epipolargleichung

Eigenschaften der Homographiematrix

Charakterisierung durch Singulärwertzerlegung

- Eine Matrix H ist genau dann Homographiematrix, wenn für die Singulärwertzerlegung von H gilt:

$$H = U \begin{bmatrix} \sigma_1 & & \\ & 1 & \\ & & \sigma_3 \end{bmatrix} V^\top$$

Scheitern des 8-Punkt-Algorithmus im planaren Fall


- Planare Epipolargleichung $\mathbf{x}_2 \sim H\mathbf{x}_1$
- \mathbf{x}_2 orthogonal zu $\mathbf{u} \times H\mathbf{x}_1$ für alle $\mathbf{u} \in \mathbb{R}^3$

- Für ideale KP hat
Koeffizientenmatrix $A := \begin{bmatrix} \mathbf{a}^1 \top \\ \mathbf{a}^2 \top \\ \vdots \\ \mathbf{a}^n \top \end{bmatrix} \in \mathbb{R}^{n \times 9}, \quad \mathbf{a}^j := \mathbf{x}_1^j \otimes \mathbf{x}_2^j$

$$\dim(\text{Ker}(A)) \geq 3 \text{ und } \text{Rang}(A) \leq 6$$

Planare Epipolargeometrie Schlussfolgerungen

- Für jedes Bild \mathbf{x}_1 eines Punktes in der Ebene existiert ein eindeutiger KP \mathbf{x}_2



- Epipolarlinien durch Homographie bestimmt
 $\ell_2 \sim \hat{\mathbf{x}}_2 H \mathbf{x}_1, \quad \ell_1 \sim H^\top \ell_2$


Zusammenfassung

- Im planaren Fall liegen 3D-Raumpunkte auf einer Ebene in der Szene
- Planare Epipolargleichung beschreibt formellen Zusammenhang der Bildpunkte
- Eindeutige Bestimmung von Korrespondenzen mit Hilfe der Homographiematrix
- Homographiematrix erlaubt die Berechnung von Epipolarlinien auch für Punkte außerhalb der Ebene

Martin Kleinsteuber: Computer Vision

Kapitel 4 – Planare Szenen

2. Der 4-Punkt-Algorithmus



Motivation

planare Szene



- Wie schätzt man die Homographiematrix aus planaren KP?
- Wie extrahiert man daraus die euklidische Bewegung?
- Wie hängen die Homographiematrix und die essentielle Matrix zusammen?

4-Punkt-Algorithmus zur Schätzung der Homographiematrix

Motivation / Voraussetzungen

- Gegeben: n Korrespondenzpunktpaare $(\mathbf{x}_1^j, \mathbf{x}_2^j)$ von Punkten in einer Ebene
- Idealerweise erfüllen alle KP die planare Epipolargleichung

$$\hat{\mathbf{x}}_2^j H \mathbf{x}_1^j = 0$$
- Ziel: Berechne die Homographiematrix H aus den geschätzten KP
 $H \in \mathbb{R}^{3 \times 3}$, somit 9 Unbekannte
- Skalierungsinvarianz: Wenn H Lösung ist, dann auch
 $\lambda H, \quad \lambda \in \mathbb{R}$

Vektorisierte planare Epipolargleichung

- Bislang: $\hat{\mathbf{x}}_2^j H \mathbf{x}_1^j = 0$
- $\text{Rang}(\hat{\mathbf{x}}_2) = 2$, also i.A. auch $\text{Rang}(B) = 2$
- Für jedes ideale Korrespondenzpunktpaar $(\mathbf{x}_1^j, \mathbf{x}_2^j)$ enthält das homogene LGS $B^j \top \mathbf{H}^s = 0$ in der Regel zwei unabhängige Gleichungen
- Benötige mind. 4 allgemein liegende Korrespondenzpunktpaare

Kronecker-Produkt \otimes

$$\mathbf{x}_1 = \begin{bmatrix} x_1 \\ y_1 \\ z_1 \end{bmatrix} \quad \hat{\mathbf{x}}_2 = \begin{bmatrix} 0 & -z_2 & y_2 \\ z_2 & 0 & -x_2 \\ -y_2 & x_2 & 0 \end{bmatrix}$$

$$B := \mathbf{x}_1 \otimes \hat{\mathbf{x}}_2 = \begin{bmatrix} x_1 \hat{x}_2 \\ y_1 \hat{x}_2 \\ z_1 \hat{x}_2 \end{bmatrix} \in \mathbb{R}^{9 \times 3}$$

Der 4-Punkt-Algorithmus

- Aus n Korrespondenzpunktpaaren ergibt sich das homogene lineare Gleichungssystem $A \mathbf{H}^s = 0$, mit $A := \begin{bmatrix} B^1 \top \\ B^2 \top \\ \vdots \\ B^n \top \end{bmatrix} \in \mathbb{R}^{3n \times 9}$
- Löse Minimierungsproblem

$$\mathbf{H}_L^s = \arg \min_{\|\mathbf{H}^s\|_2=1} \|\mathbf{A} \mathbf{H}^s\|_2^2 \text{ mittels SVD von } A$$
- $H_L := \lambda H$ sind umsortierte Einträge des rechtsseitigen Singulärvektors zum kleinsten Singulärwert, Schätzung von H bis auf Skalierung
- Aus den Eigenschaften der Homographiematrix

$$|\lambda| = \sigma_2(H_L) \text{ und somit } H = \frac{1}{\sigma_2(H_L)} H_L$$

Der 4-Punkt-Algorithmus

Vorzeichen der geschätzten Homographiematrix

- Schätzung von H bis auf Vorzeichen, $\pm H$ erfüllen planare Epipolargleichung
- Ausnutzen der Positivitätsbedingung der Tiefen führt zu Kriterium $\mathbf{x}_2^\top H \mathbf{x}_1 > 0$
- Wähle Vorzeichen von H entsprechend dieses Kriteriums


3D-Rekonstruktion aus Homographiematrix

Herleitung

- Zu einer Homographiematrix $H = (R + \frac{1}{d}\mathbf{T}\mathbf{n}^\top)$ gibt es höchstens zwei physikalisch mögliche Zerlegungen in die Parameter $\{R, \frac{1}{d}\mathbf{T}, \mathbf{n}\}$
- Eigenwertzerlegung $H^\top H = V\Sigma^2V^\top$, $V = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3] \in \text{SO}(3)$
- Definiere
$$\mathbf{u}_1 := \frac{\sqrt{1-\sigma_3^2}\mathbf{v}_1 + \sqrt{\sigma_1^2-1}\mathbf{v}_3}{\sqrt{\sigma_1^2-\sigma_3^2}}, \quad \mathbf{u}_2 := \frac{\sqrt{1-\sigma_3^2}\mathbf{v}_1 - \sqrt{\sigma_1^2-1}\mathbf{v}_3}{\sqrt{\sigma_1^2-\sigma_3^2}}$$
- Definiere
$$U_1 := [\mathbf{v}_2 \ \mathbf{u}_1 \ \hat{\mathbf{v}}_2\mathbf{u}_1], \quad W_1 := [H\mathbf{v}_2 \ H\mathbf{u}_1 \ \widehat{H\mathbf{v}_2}H\mathbf{u}_1]$$
$$U_2 := [\mathbf{v}_2 \ \mathbf{u}_2 \ \hat{\mathbf{v}}_2\mathbf{u}_2], \quad W_2 := [H\mathbf{v}_2 \ H\mathbf{u}_2 \ \widehat{H\mathbf{v}_2}H\mathbf{u}_2]$$

3D-Rekonstruktion aus Homographiematrix

4 Lösungen



| | |
|--|--|
| <p>Lösung 1:</p> $R_1 = W_1 U_1^\top$ $\mathbf{n}_1 = \mathbf{v}_2 \mathbf{u}_1$ $\frac{1}{d} \mathbf{T}_1 = (H - R_1) \mathbf{n}_1$ | <p>Lösung 3:</p> $R_3 = R_1$ $\mathbf{n}_3 = -\mathbf{n}_1$ $\frac{1}{d} \mathbf{T}_3 = -\frac{1}{d} \mathbf{T}_1$ |
| <p>Lösung 2:</p> $R_2 = W_2 U_2^\top$ $\mathbf{n}_2 = \mathbf{v}_2 \mathbf{u}_2$ $\frac{1}{d} \mathbf{T}_2 = (H - R_2) \mathbf{n}_2$ | <p>Lösung 4:</p> $R_4 = R_2$ $\mathbf{n}_4 = -\mathbf{n}_2$ $\frac{1}{d} \mathbf{T}_4 = -\frac{1}{d} \mathbf{T}_2$ |

Homographiematrix und essentielle Matrix

Zusammenhänge

- Betrachte $E = \hat{\mathbf{T}}R$ und $H = R + \mathbf{T}\mathbf{u}^\top$, $R \in \mathbb{R}^{3 \times 3}$, $\mathbf{T}, \mathbf{u} \in \mathbb{R}^3$, $\|\mathbf{T}\| = 1$
- Dann gilt
 - $E = \hat{\mathbf{T}}H$
 - $H^\top E + E^\top H = 0$
 - $H = \hat{\mathbf{T}}^\top E + \mathbf{T}\mathbf{v}^\top$ für ein bestimmtes $\mathbf{v} \in \mathbb{R}^3$

Homographiematrix und essentielle Matrix

Berechnung der essentiellen Matrix aus der Homographiematrix

- Homographiematrix H bekannt
- Habe außerdem zwei KP-Paare $(\mathbf{x}_1^j, \mathbf{x}_2^j)$, $j = 1, 2$, deren 3D-Punkte nicht auf der Ebene zur Homographiematrix liegen
- Epipolarlinien $\ell_2^j \sim \hat{\mathbf{x}}_2^j H \mathbf{x}_1^j$ schneiden sich im Epipol $\mathbf{e}_2 \sim \mathbf{T}$
- Dann gilt $E = \hat{\mathbf{T}} H$ mit $\mathbf{T} \sim \hat{\ell}_2^1 \ell_2^2$ und $\|\mathbf{T}\|_2 = 1$

Homographiematrix und essentielle Matrix

Berechnung der Homographiematrix aus der essentiellen Matrix

- Essentielle Matrix E bekannt
- Habe außerdem drei KP-Paare $(\mathbf{x}_1^j, \mathbf{x}_2^j)$, $j = 1, 2, 3$, deren 3D-Punkte eine Ebene im Raum definieren
- Dann gilt $H = \hat{\mathbf{T}}^\top E + \mathbf{T} \mathbf{v}^\top$ mit $\mathbf{v} \in \mathbb{R}^3$, welches das Gleichungssystem $\hat{\mathbf{x}}_2^j (\hat{\mathbf{T}}^\top E + \mathbf{T} \mathbf{v}^\top) \mathbf{x}_1^j = 0$, $j = 1, 2, 3$ löst


Zusammenfassung

- 4-Punkt-Algorithmus zur Bestimmung der Homographiematrix
- Zwei physikalisch plausible Lösungen für die Parameter der 3D-Rekonstruktion
- Mit Hilfe von weiteren Korrespondenzpunkten lässt sich die essentielle Matrix aus der Homographie bestimmen und umgekehrt

Martin Kleinstеuber: Computer Vision

Kapitel 4 – Planare Szenen

3. Kamerakalibrierung



Motivation



- Bestimme Kalibrierungsmatrix K aus mehreren Ansichten eines Schachbretts
- Nutze dabei Kenntnis über die Geometrie des Schachbrettes

Wiederholung

Perspektivische Projektion

- Pixelkoordinaten
- Perspektivische Projektion

$$\mathbf{x}' = K_s \mathbf{x} \quad \mathbf{x} \sim K_f \Pi_0 \mathbf{P}$$

$$\mathbf{x}' \sim K_s K_f \Pi_0 \mathbf{P} = \underbrace{\begin{bmatrix} s_x & s_\theta & o_x \\ 0 & s_y & o_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} f & 0 & 0 \\ 0 & f & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{:=K} \underbrace{\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}}_{\Pi_0} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

- Mit euklidischer Transformation von \mathbf{P}

$$\mathbf{x}' \sim K \Pi_0 \begin{bmatrix} R & \mathbf{T} \\ 0 & 1 \end{bmatrix} \mathbf{P}$$

Video


Kalibrierung

Ansatz

- Schachbrett liegt im Ursprung der Weltkoordinaten
- Z-Achse der Weltkoordinaten senkrecht zum Schachbrett

- Dann gilt für einen Punkt $\mathbf{P} = \begin{bmatrix} X \\ Y \\ 0 \\ 1 \end{bmatrix}$ auf dem Schachbrett

$$\mathbf{x}' \sim K \Pi_0 \begin{bmatrix} R & \mathbf{T} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ 0 \\ 1 \end{bmatrix} = K \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{T} \end{bmatrix} \begin{bmatrix} X \\ Y \\ 1 \end{bmatrix}$$



Video

Kalibrierung

Schätzen der Homographie

- Die Matrix $H := K \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{T} \end{bmatrix}$ ist bis auf Skalierung eine Homographiematrix, die homogene Koordinaten vom Schachbrett auf homogene, unkalibrierte Koordinaten in der Bildebene abbildet:

$$\hat{\mathbf{x}}' H \begin{bmatrix} X \\ Y \\ 1 \end{bmatrix} = 0$$

- Schätze H bis auf Skalierung mittels des 4-Punkt-Algorithmus

durch gegebene Korrespondenzpunktpaare $\left(\mathbf{x}'^j, \begin{bmatrix} X^j \\ Y^j \\ 1 \end{bmatrix} \right)$

Video

Kalibrierung

Bedingungen an die Kalibrierungsmatrix

- Es gilt $K^{-1} [\mathbf{h}_1 \quad \mathbf{h}_2] \sim [\mathbf{r}_1 \quad \mathbf{r}_2]$
- Durch Orthogonalität und Normierung von \mathbf{r}_1 und \mathbf{r}_2 erhalten wir die Bedingungen:
 - $\mathbf{h}_1^\top K^{-\top} K^{-1} \mathbf{h}_2 = 0$
 - $\mathbf{h}_1^\top K^{-\top} K^{-1} \mathbf{h}_1 = \mathbf{h}_2^\top K^{-\top} K^{-1} \mathbf{h}_2$
- Die Matrix $K^{-\top} K^{-1}$ ist symmetrisch:

$$B := K^{-\top} K^{-1} = \begin{bmatrix} B_{11} & B_{12} & B_{13} \\ B_{12} & B_{22} & B_{23} \\ B_{13} & B_{23} & B_{33} \end{bmatrix}$$

Video

Kalibrierung

Schätzen der Kalibrierungsmatrix

- Das Produkt $\mathbf{a}^\top B \mathbf{c}$ mit $\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix}$, $\mathbf{c} = \begin{bmatrix} c_1 \\ c_2 \\ c_3 \end{bmatrix}$ lässt sich

umformulieren zu $\mathbf{a}^\top B \mathbf{c} = \mathbf{v}_{(\mathbf{a}, \mathbf{c})}^\top \mathbf{b}$ mit $\mathbf{v}_{(\mathbf{a}, \mathbf{c})} = \begin{bmatrix} a_1 c_1 \\ a_1 c_2 + a_2 c_1 \\ a_2 c_2 \\ a_3 c_1 + a_1 c_3 \\ a_3 c_2 + a_2 c_3 \\ a_3 c_3 \end{bmatrix}$

und $\mathbf{b} = [B_{11}, B_{12}, B_{22}, B_{13}, B_{23}, B_{33}]^\top \in \mathbb{R}^6$

Video

Kalibrierung

Schätzen der Kalibrierungsmatrix

- Für jede Ansicht liefern die Bedingungen

- $\mathbf{h}_1^\top B \mathbf{h}_2 = 0$
- $\mathbf{h}_1^\top B \mathbf{h}_1 = \mathbf{h}_2^\top B \mathbf{h}_2$

zwei Gleichungen

$$V^j \mathbf{b} = \begin{bmatrix} \mathbf{v}_{(\mathbf{h}_1, \mathbf{h}_2)}^\top \\ (\mathbf{v}_{(\mathbf{h}_1, \mathbf{h}_1)} - \mathbf{v}_{(\mathbf{h}_2, \mathbf{h}_2)})^\top \end{bmatrix} \mathbf{b} = \mathbf{0}$$

- Für n Ansichten des Schachbretts ergibt sich das Gleichungssystem $V\mathbf{b} = \mathbf{0}$ mit $V \in \mathbb{R}^{2n \times 6}$
- Wir benötigen also mindestens 3 Ansichten, um \mathbf{b} bis auf Skalierung zu schätzen

Video

Kalibrierung

Schritte zur Berechnung der Kalibrierungsmatrix

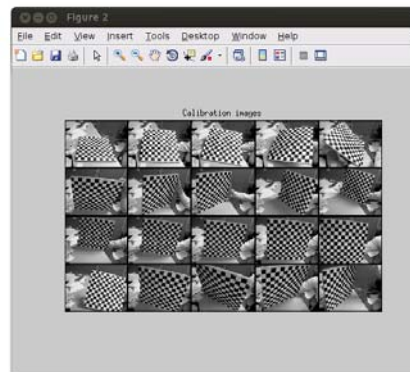
- Löse LGS $V\mathbf{b} = \mathbf{0}$ mittels Singulärwertzerlegung von V
- Erstelle symmetrische Matrix \tilde{B} aus dem rechtsseitigen Singulärvektor zum kleinsten Singulärwert von V
- Wähle positiv definites $B = \pm \tilde{B}$
- Zerlege B mittels Cholesky-Faktorisierung in das Produkt $B = \tilde{K}^\top \tilde{K}$, wobei \tilde{K} eine obere Dreiecksmatrix ist
- Dann gilt $K \sim \tilde{K}^{-1}$
- Normiere die Kalibrierungsmatrix an Hand ihres (3,3)-Eintrags

Video

MATLAB-Demonstration

Toolbox zur Kamerakalibrierung

- Jean-Yves Bouget, CalTech
- http://www.vision.caltech.edu/bouguetj/calib_doc/index.html



Zusammenfassung

- Mit mindestens drei Aufnahmen eines Schachbretts lässt sich die Kalibrierungsmatrix bestimmen
- Erhalte pro Aufnahme eine Homographie zwischen 3D-Punkten auf dem Schachbrett und zugehörigen unkalibrierten Bildpunkten
- Jede Ansicht liefert zwei Gleichungen für $B = K^{-\top} K^{-1}$
- Extrahiere die Kalibrierungsmatrix mittels Cholesky-Faktorisierung